

# **Impacto de la Contaminación Atmosférica en los Casos de Asma en California**

Grupo Morado:

Julio Agüero Encinas

Fabián Camargo

Miguel Corvo Domosti

Samuel Martín Martínez

Jiaze Zhang

Curso 2025-2026

# Índice general

<b>1. Impacto de la calidad del aire sobre la calidad de vida</b>	<b>3</b>
1.1. Problemática y objetivos . . . . .	3
1.2. Marco teórico . . . . .	5
1.2.1. Calidad del aire y contaminantes . . . . .	5
<b>2. Fuentes de datos</b>	<b>6</b>
2.1. Datos de calidad del aire . . . . .	6
2.1.1. Geografía de California . . . . .	7
2.1.2. Descarga de datos históricos . . . . .	11
2.1.3. Procesamiento de los datos descargados . . . . .	13
2.2. Datos de prevalencia de asma en California . . . . .	16
2.3. Limitaciones de las fuentes de datos . . . . .	19
<b>3. Plan de Preservación</b>	<b>20</b>
3.1. Almacenamiento . . . . .	20
3.1.1. Almacenamiento físico . . . . .	20
3.2. Gestión de los datos . . . . .	21
3.2.1. Limpieza y curación . . . . .	21
3.2.2. Metadatos . . . . .	22
3.2.3. Acceso y reutilización . . . . .	22
3.3. Seguridad . . . . .	22
3.4. Estrategia de preservación a largo plazo . . . . .	23
3.4.1. Backup . . . . .	24
3.4.2. Almacenamiento en la nube . . . . .	25
<b>A. Código para la fase ETL</b>	<b>26</b>
A.1. Extracción de datos de OpenAQ . . . . .	27
A.2. Esquema de primera fuente de datos . . . . .	28

A.3. Esquema de segunda fuente de datos . . . . .	30
---	----

# Capítulo 1

## Impacto de la calidad del aire sobre la calidad de vida

### 1.1. Problemática y objetivos

#### Problemática

En las últimas décadas, el modelo de éxito de las sociedades modernas se ha vinculado frecuentemente a la expansión económica fundamentada en la industrialización. Tradicionalmente, esta estrategia no ha prestado atención a los efectos colaterales pertinentes a la salud pública y al medio ambiente.

A medida que las ciudades se expanden y las actividades comerciales se intensifican, el impacto sobre el entorno natural se desplaza a un segundo plano, considerándose a menudo como un efecto secundario inevitable del desarrollo.

Este descuido del entorno tiene usualmente una repercusión directa y alarmante en la salud de la población. La prioridad por sostener una economía de alto rendimiento ha derivado en una degradación de la calidad del aire que respiramos. Al no prestar debidamente atención a las emisiones derivadas de estos sistemas, se han creado condiciones ambientales que no solo causan la aparición de nuevas enfermedades respiratorias, sino que agravan seriamente las ya existentes, como es el caso del asma.

En regiones con un alto desarrollo logístico e industrial, los contaminantes que actúan como detonantes de crisis respiratorias.

## Objetivos

El objetivo principal del proyecto será instaurar una monitorización de los contaminantes a lo largo del Estado de California, EEUU, y con ello aumentar el control estricto del impacto negativo de estos en la salud de la población, de acuerdo a los estándares propios de la OMS [7], que establecen unas recomendaciones sobre los niveles de materia particulada, ozono, óxidos de nitrógeno, azufre y monóxido de carbono. Esto se manifiesta en límites horarios, octo-horarios, diarios y anuales.

Para este proyecto, son de especial interés los siguientes contaminantes:

- **Dióxido de nitrógeno ( $\text{NO}_2$ )**

Ciertos estudios lo relacionan con un aumento del riesgo en el desarrollo de asma durante la infancia, como [3].)

También se ha observado lo mismo en adultos, aunque con mayor heterogeneidad en los resultados [2].

Si bien en este último estudio se reconoce que las conclusiones son limitadas, puesto que muchos estudios se apoyan en asma definida por cuestionarios y no en diagnósticos clínicos, entre otros factores.

- **Materia particulada fina ( $\text{PM}_{2,5}$  y  $\text{PM}_{10}$ )**

Su exposición aumenta el riesgo de desarrollo de asma en la infancia.

En el caso de  $\text{PM}_{2,5}$  es más homogéneo y exacerbado a partir de los 6 años continuados de exposición.

En el caso de  $\text{PM}_{10}$  se ha observado un aumento del riesgo en todos los grupos de edad [2].

- **Ozono ( $\text{O}_3$ ) a nivel del suelo**

Debido a la reducción en capacidad pulmonar de los pacientes asmáticos, tras la exposición a este contaminante, se ha observado un aumento en las crisis asmáticas y en las hospitalizaciones relacionadas con el asma [6].

Así mismo, se busca aumentar la concienciación de la sociedad hacia las consecuencias de la industrialización en la salud.

1. Obtener datos de niveles de  $\text{NO}_2$ ,  $\text{O}_3$  y  $\text{PM}_{2,5}$ .
2. Analizar la correlación con ingresos hospitalarios.
3. Identificar áreas que requieren medidas de mitigación urgentes.

## **1.2. Marco teórico**

### **1.2.1. Calidad del aire y contaminantes**

Se monitorean gases como el dióxido de nitrógeno ( $NO_2$ ) y ozono ( $O_3$ ), los cuales son tóxicos y causan problemas como asma y bronquitis[cite: 57, 72].

# Capítulo 2

## Fuentes de datos

En este capítulo se describen las fuentes de datos utilizadas en el análisis del impacto de la contaminación atmosférica en los casos de asma en California.

Se detallan las características de cada conjunto de datos, su origen, y cómo se integran en el estudio. En este estudio se han empleado principalmente dos fuentes de datos:

- Datos de calidad del aire obtenidos de la iniciativa [OpenAQ](#).
- Datos de prevalencia de asma en la población californiana proporcionados por [data.gov](#), la plataforma de datos abiertos del gobierno de Estados Unidos.

Para la extracción y filtrado de los datos, se han realizado una serie de tareas que se describirán en detalle en las secciones siguientes.

Todo este proceso ha sido recogido en un cuaderno de Jupyter, que se puede localizar en el repositorio del proyecto, en la ruta `code/ETL Source I.ipynb`.

A lo largo de las secciones, se facilitarán algunas capturas de pantalla de fragmentos del cuaderno para ilustrar ciertas partes del proceso.

### 2.1. Datos de calidad del aire

Los datos de calidad del aire se han obtenido de la iniciativa [OpenAQ](#), que proporciona acceso abierto a mediciones de contaminantes atmosféricos a nivel global.

Entre otros contaminantes, las entidades colaboradoras exponen datos sobre niveles de dióxido de nitrógeno ( $NO_2$ ), ozono ( $O_3$ ) y material particulado fino ( $PM_{2,5}$ ), que son relevantes para el estudio del asma.

Además de ofrecer un visor web, OpenAQ cuenta con una API que permite la descarga programática de datos históricos y en tiempo real. En la documentación oficial de la API se detallan los *endpoints* disponibles, los parámetros de consulta y los formatos de respuesta. En concreto, es de particular relevancia el hecho de que la API tiene un límite de peticiones para distintas franjas temporales. En el caso de California, ha sido de relevancia considerar los siguientes límites, cuyas razones revelaremos más adelante:

- 60 peticiones por minuto.
- 2000 peticiones por hora.

Estas restricciones han sido el principal cuello de botella a la hora de descargar grandes volúmenes de datos históricos.

### 2.1.1. Geografía de California

Los datos expuestos por el gobierno de Estados Unidos están desglosados por condados, que son las subdivisiones administrativas de primer nivel dentro de los estados.

Esto es de relevancia, puesto que las estaciones de medición de calidad del aire exponen su ubicación geográfica en coordenadas de latitud y longitud (EPSG:4326), por lo que es necesario asignar cada estación a su condado correspondiente.

Para este cometido, se han realizado dos tareas principales:

- **Obtener los límites geográficos de los condados de California.**

Para ello, se han empleado los datos de *shapefiles* proporcionados por el *U.S. Census Bureau* [5]. Estos archivos contienen la geometría de los condados, que se ha utilizado para determinar si una estación de medición se encuentra dentro de un condado específico.

- **Filtrar las estaciones de medición mediante un bbox**

(*bounding box*, i.e., un rectángulo delimitador) que englobe toda California, puesto que la API de OpenAQ permite filtrar por este criterio.

A continuación se muestra el código empleado para descargar los shapefiles de los condados:

<sup>1</sup>

<sup>2</sup> `import requests`

<sup>3</sup> `from pathlib import Path`

```

4 # download county shapefiles from US Census Bureau
5 shapes_url =
6   ↵  'https://www2.census.gov/geo/tiger/TIGER2025/COUNTY/tl_2025_us_county.zip'
7 geo_dir = Path("data/geographical")
8 geo_dir.mkdir(parents=True, exist_ok=True)
9 shapes_path = geo_dir / "tl_2025_us_county.zip"
10 if not shapes_path.exists():
11     print(f"Downloading county shapefiles from {shapes_url}...")
12     r = requests.get(shapes_url)
13     with open(shapes_path, 'wb') as f:
14         f.write(r.content)
15     print(f"Downloaded to {shapes_path}")
16 else:
17     print(f"Shapefiles already exist at {shapes_path}")

```

El archivo comprimido descargado se encuentra en la ruta `data/geographical/tl_2025_us_county.zip`, cuya versión descomprimida se halla en la sub-carpeta `california_counties`; en caso de que el lector desee explorar los archivos.

En la Figura 2.1 se muestra una captura de pantalla de los condados de Estados Unidos visualizados en QGIS, un software de sistemas de información geográfica (*GIS*).

Los condados de California están resaltados en rosa.

Son de particular interés las siguientes columnas:

- `STATEFP`: código FIPS del estado (California es 06).
- `NAME`: nombre del condado, valor que empleamos para relacionarlo con los datos de asma.
- `geometry`: geometría del condado en formato poligonal, es decir, una cadena de texto en formato WKT (*Well-Known Text*).

Se facilita un ejemplo ilustrativo en la Figura 2.2.

Para procesar estos datos geográficos, se ha empleado la librería `geopandas`, que extiende las funcionalidades de `pandas` para manejar datos espaciales.

En concreto, nos permite usar el método `Polygon.contains()` para determinar si las coordenadas de una estación de medición están dentro de la geometría de un condado.




Figura 2.1: Visualización de condados en QGIS

```
1 POLYGON ((-122.373121 37.883884, -122.371142 37.884364, ... ))
```

Figura 2.2: Ejemplo: geometría en WKT (ilustrativo)

Una vez que tenemos definido el flujo a seguir para clasificar las estaciones por condado, procedemos a exponer la cuestión de decidir cómo filtrar las estaciones de interés a través de la API de OpenAQ.

Como ya se ha mencionado, la API permite filtrar las estaciones mediante un *bounding box*, que se define por las coordenadas de sus esquinas suroeste y noreste.

Para California, simplemente se ha usado QGIS para obtener unas coordenadas aproximadas que engloban todo el estado. En la Figura 2.3 se muestra una captura de pantalla de QGIS donde se procede a copiar las coordenadas.




Figura 2.3: Obtención del bbox de California en QGIS

Se puede consultar el código empleado en la Sección A.1.

Posteriormente, estos datos se han procesado para asignar cada estación a su condado correspondiente, como se ha descrito anteriormente.

Se proporciona una tabla con la distribución de estaciones por condado en California (se ha mostrado solo los 10 primeros condados ordenados por recuento) en la Tabla 2.1.

Cuadro 2.1: Recuento por condado

Condado	Recuento
Los Angeles	403
Alameda	190
Mono	94
Contra Costa	87
Sacramento	83
San Francisco	66
Monterey	50
Sonoma	48
San Diego	46
San Luis Obispo	44

## 2.1.2. Descarga de datos históricos

Ahora que tenemos los datos de las estaciones de interés, el siguiente paso es realizar una petición a la API de OpenAQ para descargar los datos históricos de calidad del aire.

La documentación oficial de la API se puede consultar en la fuente [4].

La API devuelve información sobre los sensores de cada estación, que miden distintos contaminantes atmosféricos.

A partir de esto, se ha diseñado un bucle que itera sobre los 5333 sensores identificados en California, empleando el *endpoint /sensors* de la API.

Dado que la API impone límites en el número de peticiones por minuto y por hora, se ha implementado una lógica para monitorizar las cabeceras de respuesta **X-Rate-Limit-Remaining** y pausar las peticiones cuando sea necesario.

Este proceso ha tenido una naturaleza iterativa en cuanto al código, puesto que han surgido varios inconvenientes durante la descarga masiva de datos.

Sin embargo, puesto que se han guardado los datos descargados en archivos intermedios, no se ha perdido el progreso realizado hasta el momento.

Es por esta razón que la barra de progreso muestra un tiempo estimado menor del real.

Teniendo en cuenta los límites impuestos por la API, se estima que la descarga completa de los datos históricos de calidad del aire en California lleva entre 2 y 3 horas.

Se adjunta una captura de pantalla en la Figura 2.4 que ilustra el progreso de la descarga.

```

# The API has a rate limit of 60 per minute and 2000 per hour.
from tqdm import tqdm
import time, requests

SENSOR_BASE = "https://api.openaq.org/v3/sensors"
aq_data_path = Path("data/openaq_data")
aq_data_path.mkdir(parents=True, exist_ok=True)
pbar = tqdm(total=selected_stations['sensors_count'].sum())
headers = {"X-API-Key": API_KEY}

for _, row in selected_stations.iterrows():
    station = row
    sensors_list = json.loads(row['sensors'].replace("", ""))
    for sensor in sensors_list:
        # check if sensor data file already exists
        sensor_filename = aq_data_path / "sensors" / f"sensor_{sensor['id']}.json"
        if sensor_filename.exists():
            pbar.update(1)
            continue
        sensor_id = sensor['id']
        r = requests.get(
            f"{SENSOR_BASE}/{sensor_id}/measurements",
            headers=headers,
            timeout=60,
            params={
                "date_from": "2015-01-01T00:00:00+00:00",
                "date_to": "2024-12-31T23:59:59+00:00",
            }
        )
        if r.headers.get('X-RateLimit-Remaining') == '0':
            reset_time = int(r.headers.get('X-RateLimit-Reset', 60))
            pbar.set_description(f"Rate limit reached. Sleeping for {reset_time + 1} seconds...")
            time.sleep(reset_time + 1)
        r = requests.get(
            f"{SENSOR_BASE}/{sensor_id}/measurements",
            headers=headers,
            timeout=60,
            params={
                "date_from": "2015-01-01T00:00:00+00:00",
                "date_to": "2024-12-31T23:59:59+00:00",
            }
        )
        sensor_data = r.json().get("results", {})
        # save sensor data to file
        sensor_file_path = aq_data_path / "sensors" / f"sensor_{sensor_id}.json"
        with open(sensor_file_path, 'w') as f:
            json.dump(sensor_data, f, indent=4)
        pbar.set_description(f"Saved sensor data to {sensor_file_path}")
        # append to metadata dataframe
        pbar.update(1)
        if r.headers.get('X-RateLimit-Remaining') == '0':
            reset_time = int(r.headers.get('X-RateLimit-Reset', 60))
            pbar.set_description(f"Rate limit reached. Sleeping for {reset_time + 1} seconds...")
            time.sleep(reset_time + 1)
    pbar.close()

Saved sensor data to data/openaq_data/sensors/sensor_14949145.json: 100%|██████████| 5333/5333 [43:04<00:00,  2.06it/s]

```

Figura 2.4: Celda del cuaderno ilustrando las peticiones

Puesto que se han guardado los datos descargados en archivos JSON individuales, se ha optado por comprimirlos en un archivo ZIP para facilitar su manipulación posterior. Además, puesto que no se van a modificar, facilita su almacenamiento y distribución. El bucle se puede consultar en el cuaderno de Jupyter. No lo incluimos aquí por su extensión. En la Figura 2.5 se muestra un ejemplo de la estructura de una respuesta en formato JSON, cuyo contenido ha sido truncado para mayor claridad.

```

1  [
2      {
3          "value": 9.0,
4          "flagInfo": {
5              "hasFlags": false
6          },
7          "parameter": {
8              "id": 2,
9              "name": "pm25",
10             "units": "\u00b5g/m\u00b3",
11             "displayName": null
12         },
13         "period": {
14             "label": "raw",
15             "interval": "01:00:00",
16             "datetimeFrom": {
17                 "utc": "2016-03-06T19:00:00Z",
18                 "local": "2016-03-06T11:00:00-08:00"
19             },
20             "datetimeTo": {
21                 "utc": "2016-03-06T20:00:00Z",
22                 "local": "2016-03-06T12:00:00-08:00"
23             }
24         },
25     },
26     ...
27 ]

```

Figura 2.5: Ejemplo de respuesta JSON de la API de OpenAQ

### 2.1.3. Procesamiento de los datos descargados

Con la idea de integrar los datos de calidad del aire con los datos de asma, se ha creado una base de datos SQLite para facilitar el análisis posterior.

Se ha diseñado un esquema de base de datos que incluye tablas para las estaciones de medición, los sensores, las mediciones realizadas ... entre otros.

El esquema de las tablas se puede consultar en la Sección A.2.

En la Figura 2.6 se muestra un esquema generado por DBeaver de la base de datos.




Figura 2.6: Esquema de la BD en la Fase I

Más adelante, la base de datos se ampliará para incluir los datos de asma, permitiendo realizar consultas complejas que relacionen ambos conjuntos de datos.

## Descripción del esquema de la base de datos

El esquema modela un sistema de **monitoreo ambiental** basado en estaciones y sensores, donde se registran mediciones de contaminantes a lo largo del tiempo. La estructura se compone de seis tablas principales y varias relaciones mediante claves foráneas.

- **units**: almacena las **unidades de medida** usadas en las mediciones (por ejemplo,  $\mu\text{g}/\text{m}^3$ ,  $\text{ppm}$ ). Contiene un identificador (`unit_id`), el nombre de la unidad (`unit_name`) y una descripción opcional (`description`).
- **pollutants**: catálogo de **contaminantes** medidos (por ejemplo,  $\text{NO}_2$ ,  $\text{PM}2.5$ ,  $\text{O}_3$ ). Incluye `pollutant_id` y `pollutant_name`.
- **counties**: representa las **entidades geográficas** (condados). Guarda `county_id`, el nombre (`county_name`) y un campo `geometry` para almacenar la geometría (típicamente en formato texto, p. ej. WKT/GeoJSON).
- **stations**: define las **estaciones de monitoreo** asociadas a un condado. Cada estación (`station_id`) puede tener un `county_id` (clave foránea a **counties**) y coordenadas geográficas (`latitude`, `longitude`).

- **sensors**: modela los **sensores instalados en estaciones**. Un sensor (`sensor_id`) pertenece a una estación (`station_id`) y está asociado a un contaminante (`pollutant_id`) y a una unidad de medida (`unit_id`). Estas relaciones se implementan con claves foráneas hacia `stations`, `pollutants` y `units`.
- **measurements**: almacena las **mediciones** generadas por cada sensor.

Incluye `measurement_id`, el sensor (`sensor_id`), el valor medido (`measurement_value`) y el intervalo temporal de validez (`start_time`, `end_time`). Además, se define una restricción `UNIQUE(sensor_id, start_time, end_time)` para evitar duplicados del mismo sensor en el mismo intervalo.

## Relaciones principales

- Un **condado** (`counties`) puede tener muchas **estaciones** (`stations`). Esto se define con `stations.county_id → counties.county_id`.
- Una **estación** puede tener muchos **sensores**. Esto se define con `sensors.station_id → stations.station_id`.
- Un **sensor** mide un **contaminante** y usa una **unidad**.  
Esto se define con `sensors.pollutant_id → pollutants.pollutant_id` y `sensors.unit_id → units.unit_id`.
- Un **sensor** genera muchas **mediciones**. Esto se define con `measurements.sensor_id → sensors.sensor_id`.

## 2.2. Datos de prevalencia de asma en California

Los datos de prevalencia de asma en California se han obtenido de `data.gov`, la plataforma de datos abiertos del gobierno de Estados Unidos [1].

La iniciativa CHIS (California Health Interview Survey) proporciona datos detallados sobre la salud de la población californiana, incluyendo información sobre la prevalencia de asma. Estos datos describen la proporción de personas diagnosticadas con asma en distintos condados de California, desglosados por año, grupo de edad, género y otros factores demográficos. La extensión temporal de los datos abarca desde 2015 hasta 2021 (hasta el final de año), lo que permite analizar tendencias a lo largo del tiempo, si bien de forma limitada.

Debido a la urgencia de disponer de estos datos para el análisis, se ha optado por realizar este análisis con una cantidad limitada de años.

En futuras iteraciones del proyecto, se podría ampliar el rango temporal para obtener una visión más completa de la evolución de la prevalencia de asma en California.

Es por esto que se ha optado emplear una base de datos SQLite para integrar estos datos con los de calidad del aire. Permitiendo un mayor grado de extensibilidad y flexibilidad en el análisis posterior.

Similarmente a la fase anterior, se puede consultar el esquema actualizado de la base de datos en la Sección A.3.

El diagrama generado por DBeaver se muestra en la Figura 2.7.




Figura 2.7: Esquema tras implementar la segunda fuente

## Descripción del esquema actualizado de la base de datos

Este esquema modela un conjunto de datos de **prevención de asma** por condado y por **grupo demográfico**, incluyendo intervalos de confianza.

Cabe mencionar que algunos condados pueden agruparse en ciertas observaciones, lo que se gestiona mediante una tabla intermedia.

La tabla principal es **asthma\_prevalence**.

Cada fila representa una observación de prevalencia asociada a un **condado** (county\_id) y a un **periodo temporal** definido por year\_from y year\_to.

La prevalencia se almacena en **current\_prevalence**, y la incertidumbre se captura con el intervalo de confianza del 95 % mediante **ci\_95\_lower** y **ci\_95\_upper**.

El campo **comment** permite registrar notas o aclaraciones del dato (agrupaciones, incertidumbres...).

Además, la observación se vincula a una definición de subpoblación mediante **demographic\_group\_id**, y se mantiene integridad referencial con claves foráneas hacia **counties(county\_id)** y **demographic\_group(id)**.

La tabla `demographic_group` define los **grupos demográficos/poblacionales** empleados en el dataset.

El campo `strata` identifica la **subpoblación** al que corresponde el registro (por ejemplo, *All ages, Age groups o Child vs. Adult*).

El campo `age_group` conserva la etiqueta de edad exactamente como aparece en los datos originales.

Para facilitar análisis cuantitativos, `age_min` y `age_max` almacenan, cuando es posible, una normalización numérica del rango de edad. De esta forma es posible filtrar por intervalos (p. ej. 0–4, 5–17, 18–64, etc.) incluso si la etiqueta original es textual.

La tabla `grouped_counties` representa los casos en los que una observación del dataset corresponde a un **grupo de condados** (columna COUNTIES GROUPED).

Cada fila enlaza un `county_id` con un `asthma_prevalence_id`, permitiendo reconstruir exactamente qué condados están incluidos en esa agregación.

La clave primaria compuesta (`county_id, asthma_prevalence_id`) evita duplicidades y mantiene la consistencia de la relación.

En conjunto, el esquema separa la **medición** (prevalencia e intervalos) de las dimensiones **geográfica** (condados) y **poblacional** (estratos y edades). Esto permite consultas flexibles tanto para registros por condado individual como para resultados agregados por grupos de condados.

### 2.3. Limitaciones de las fuentes de datos

# Capítulo 3

## Plan de Preservación

El presente Plan de Preservación tiene como objetivo garantizar la integridad, disponibilidad y reutilización a largo plazo de los activos digitales generados en el proyecto *Impacto de la Contaminación Atmosférica en los Casos de Asma en California*. Dado que el estudio maneja series temporales críticas y datos de salud pública, se ha diseñado una estrategia que cubre desde el almacenamiento físico hasta la gestión de derechos de acceso, alineándose con los principios FAIR (*Findable, Accessible, Interoperable, Reusable*).

### 3.1. Almacenamiento

La estrategia de almacenamiento se ha diseñado teniendo en cuenta el volumen de los datos geo-espaciales y la necesidad de diferenciar claramente entre los datos de uso frecuente y los archivos destinados a la preservación estática.

#### 3.1.1. Almacenamiento físico

La infraestructura física local constituye el primer nivel de nuestra jerarquía de datos. Debido a la carga computacional que requieren las operaciones espaciales en **ArcGIS Pro** —especialmente el cruce de capas vectoriales de códigos postales (ZCTA) con las series temporales de contaminantes—, hemos priorizado el rendimiento en los equipos de trabajo.

Para el **almacenamiento activo**, utilizamos unidades de estado sólido (**SSD**) en las estaciones de trabajo locales. Esto nos permite evitar cuellos de botella durante la renderización de mapas y la ejecución de los scripts de limpieza en R. Adicionalmente, mantenemos un nivel de **almacenamiento en frío** (*cold storage*) mediante discos duros externos mecánicos (**HDD**) de alta capacidad. En estos dispositivos se custodian las copias originales de los *raw*

*data* descargados de la EPA y *catalog.data.gov*, liberando espacio en los discos de trabajo principales y sirviendo como repositorio local de los datos fuente inalterados.

## 3.2. Gestión de los datos

El presente estudio se adhiere a los principios FAIR (Findable, Accessible, Interoperable, Reusable) para garantizar la transparencia y la reproducibilidad de la investigación. La gestión de la información no se limita a la recolección, sino que abarca la totalidad del ciclo de vida de los datos, estableciendo procedimientos claros para su manejo desde la obtención inicial hasta su preservación a largo plazo.

### 3.2.1. Limpieza y curación

La transformación de los datos brutos en información analizable se ha llevado a cabo mediante un flujo de trabajo reproducible ejecutado en el entorno estadístico **R**. En lugar de correcciones manuales, que son propensas a errores y difíciles de auditar, hemos desarrollado scripts automatizados utilizando la librería **tidyverse** para estandarizar los formatos de fecha y unificar las unidades de medida de los contaminantes ( $NO_2$ ,  $O_3$ ) a partes por millón (ppm).

Para el tratamiento de inconsistencias, los scripts aplican reglas de validación lógica que identifican registros duplicados y valores fuera de rango. Específicamente, la detección de *outliers* en las lecturas de los sensores se realiza mediante el cálculo del rango intercuartílico (IQR), filtrando automáticamente aquellas mediciones que exceden el umbral de  $1,5 \times IQR$  por considerarse errores instrumentales. Respecto a los valores nulos (NaNs) en las series temporales, cuando los huecos de información son inferiores a 4 horas, se imputan mediante algoritmos de interpolación lineal disponibles en el paquete **zoo**, garantizando la continuidad de la serie sin introducir sesgos significativos.

Por último, la integridad espacial de los datos se verifica utilizando **ArcGIS Pro**. Antes de realizar el cruce espacial entre las estaciones de monitoreo y los códigos postales (ZCTA), empleamos las herramientas de topología de ArcGIS para asegurar que las geometrías de los *shapefiles* no presentan superposiciones ni huecos que pudieran alterar la asignación de los niveles de exposición.

### **3.2.2. Metadatos**

Para facilitar la recuperación e interpretación de los datos por terceros, se ha adoptado el esquema de metadatos estandarizado **Dublin Core**. La elección de este estándar internacional permite describir los recursos digitales mediante un conjunto de elementos esenciales —tales como Título, Creador, Cobertura Espacial, Fecha y Formato—, garantizando que el contexto de recolección y las características técnicas del *dataset* sean comprensibles sin ambigüedades para la comunidad científica.

Como parte fundamental de esta documentación, se adjunta un diccionario de datos o *codebook* detallado que define explícitamente cada variable, especifica las unidades de medida empleadas (ej. ppm o  $\mu\text{g}/\text{m}^3$ ) y desglosa el significado de cualquier codificación utilizada en las tablas. Adicionalmente, para asegurar el orden, todos los archivos siguen una convención de nombrado sistemática (ej. YYYYMMDD\_Nombre\_v01) que facilita la identificación rápida de versiones.

### **3.2.3. Acceso y reutilización**

Una vez finalizado el estudio, los datos procesados se depositarán en el repositorio de acceso abierto **Zenodo**, gestionado por el CERN. Esta plataforma asignará automáticamente un Identificador de Objeto Digital (DOI) único al conjunto de datos, asegurando que sea localizable y citable de manera permanente en futuras investigaciones.

Los datos se distribuirán bajo la licencia **Creative Commons Atribución 4.0 Internacional (CC-BY 4.0)**. Esta licencia abierta fomenta la reutilización, permitiendo a terceros compartir y adaptar el material para cualquier propósito, incluso comercial, con la única condición de reconocer la autoría original. En cuanto a las consideraciones éticas, al trabajar con datos de prevalencia agregados a nivel de condado y no con historias clínicas individuales, se garantiza la privacidad de los pacientes sin necesidad de aplicar técnicas adicionales de anonimización sobre los resultados finales.

## **3.3. Seguridad**

La seguridad de la información en este proyecto se ha abordado desde una perspectiva integral que contempla tanto la integridad de los ficheros como la privacidad de los datos sensibles, aspectos críticos cuando se trabaja con información relacionada con la salud pública. Aunque los datos de prevalencia de asma utilizados son agregados y no contienen información per-

sonal identificable (PII) de pacientes individuales, hemos aplicado protocolos estrictos para evitar cualquier riesgo de reidentificación o manipulación malintencionada de los resultados.

En primer lugar, garantizamos la integridad de los datos mediante el uso de funciones de resumen o *hashing*. Cada vez que se descarga un conjunto de datos original de las fuentes gubernamentales o se genera un *dataset* consolidado tras la limpieza, se calcula su huella digital. Esto nos permite verificar periódicamente que los archivos almacenados en nuestros discos locales no han sufrido alteraciones silenciosas, conocidas como *bit rot*, ni modificaciones accidentales durante su manipulación. Si la suma de verificación actual no coincide con la registrada originalmente, el sistema nos alerta para restaurar una copia limpia desde el sistema de copias de seguridad.

Por otro lado, el control de acceso a los datos en fase de desarrollo se gestiona mediante permisos estrictos en el repositorio de código. Hemos establecido una política de roles donde únicamente los miembros del equipo de investigación tienen permisos de escritura y modificación sobre los *scripts* de análisis y los datos brutos. Cualquier cambio en el código que procesa los datos de contaminación o salud debe pasar por una revisión por pares antes de ser fusionado con la rama principal del proyecto. Esta trazabilidad completa nos asegura que ningún dato ha sido alterado de forma arbitraria para forzar una correlación estadística inexistente, manteniendo así la ética y la validez científica del estudio.

Finalmente, para el tránsito de información entre los equipos locales y los sistemas de almacenamiento remoto, utilizamos exclusivamente protocolos cifrados. Tanto la sincronización con la nube institucional como las operaciones de confirmación de cambios en el repositorio de código se realizan a través de canales seguros HTTPS y SSH, protegiendo la propiedad intelectual del proyecto y los datos de posibles interceptaciones en redes no seguras.

### 3.4. Estrategia de preservación a largo plazo

La preservación digital a largo plazo es un desafío que va más allá del simple almacenamiento de archivos; implica asegurar que la información permanezca legible, comprensible y ejecutable a medida que la tecnología evoluciona. Nuestra estrategia se fundamenta en la migración proactiva de formatos y la documentación exhaustiva, con el objetivo de que este estudio sobre el asma en California pueda ser reproducido con exactitud dentro de diez o veinte años, independientemente del software que exista en ese momento.

Una de las decisiones más importantes que hemos tomado para garantizar esta perdurabilidad

es la renuncia al uso de formatos propietarios para el archivo definitivo. Aunque durante la fase activa del proyecto utilizamos formatos nativos de Excel o archivos de proyecto de ArcGIS Pro por su eficiencia operativa, somos conscientes de que estos formatos podrían quedar obsoletos o requerir licencias de software costosas en el futuro. Por ello, nuestra política de preservación dicta que todo activo digital debe tener una versión equivalente en un estándar abierto:

- **Datos tabulares:** Se convierten a **CSV** con codificación UTF-8, asegurando su legibilidad por cualquier editor de texto básico.
- **Datos geográficos:** La cartografía vectorial se exporta a **GeoJSON**, un formato basado en texto y ampliamente soportado.
- **Documentación:** La memoria y los manuales se archivan en **PDF/A**, el estándar ISO diseñado específicamente para el archivo a largo plazo que incrusta todas las fuentes y elementos visuales necesarios.

### 3.4.1. Backup

Para mitigar el riesgo de pérdida catastrófica de datos, ya sea por fallos de hardware, errores humanos o ataques de software malicioso, hemos implementado una política de copias de seguridad rigurosa basada en el estándar de la industria conocido como la regla **3-2-1**.

Esta metodología asegura que no existe un único punto de fallo que pueda comprometer la totalidad del proyecto.

El protocolo establecido dicta que debemos mantener en todo momento al menos **tres** copias completas de todos los datos, almacenadas en **dos** soportes de diferente naturaleza, con **una** copia ubicada fuera de sitio (*off-site*):

1. **Copia de Trabajo:** Reside en las unidades SSD locales para el procesamiento diario.
2. **Copia de Seguridad Local (Air Gap):** Se realiza semanalmente en los discos duros externos (HDD). La característica clave de esta copia es su aislamiento: los discos se mantienen **desconectados física y lógicamente** de la red y de la corriente eléctrica cuando no se está realizando la copia. Esta técnica, conocida como “brecha de aire” (*air gap*), proporciona nuestra defensa más robusta contra el *ransomware*, ya que es físicamente imposible que un software malicioso encripte una unidad que no está conectada al sistema infectado.
3. **Copia Remota:** Se almacena en la nube institucional, asegurando la recuperación ante desastres físicos en el lugar de trabajo, como incendios o robos.

### 3.4.2. Almacenamiento en la nube

El almacenamiento en la nube juega un doble rol fundamental en nuestro proyecto: facilita la colaboración distribuida durante la fase activa y actúa como repositorio final para la preservación estática.

Durante el desarrollo, utilizamos **Google Drive/OneDrive** (vinculados a cuentas institucionales) y **GitHub** para la sincronización inmediata de documentos y código entre los miembros del equipo. Sin embargo, para la preservación a largo plazo, dependemos de **Zenodo**. La elección de este repositorio del CERN no es trivial: a diferencia de las nubes comerciales que requieren pagos recurrentes o mantenimiento de cuentas activas, Zenodo garantiza la preservación de los archivos científicos durante al menos 20 años, asegurando que la evidencia generada en este estudio permanezca accesible a la comunidad científica de manera perpetua.

# Apéndice A

## Código para la fase ETL

En este apéndice se presenta el código utilizado para la fase de Extracción, Transformación y Carga (ETL) de los datos en nuestro proyecto.

Las variables no definidas en los fragmentos de código se pueden consultar en la siguiente lista:

- **API\_KEY**: Clave de API para acceder a la API de OpenAQ.
- **selected\_stations**: DataFrame de pandas que contiene las estaciones seleccionadas para la descarga de datos históricos.

## A.1. Extracción de datos de OpenAQ

```
1 # define bounding box for California
2 x_range = (-125, -113)
3 y_range = (32, 42.5)
4 import requests
5 BASE = "https://api.openaq.org/v3"
6 headers = {"X-API-Key": API_KEY}
7 all_results = []
8 page = 1
9 limit = 1000    # OpenAQ v3 maximum
10 while True:
11     r = requests.get(
12         f"{BASE}/locations",
13         headers=headers,
14         params={
15             "bbox": f"{x_range[0]},{y_range[0]},{x_range[1]},{y_range[1]}",
16             "limit": limit,
17             "page": page,
18             "country": "US",    # optional but helps validation
19         },
20         timeout=60,
21     )
22     r.raise_for_status()
23     data = r.json()
24
25     results = data.get("results", [])
26     if not results:
27         break
28
29     all_results.extend(results)
30     print(f"page {page}: {len(results)}")
31
32     page += 1
33
34 print("TOTAL returned:", len(all_results))
35 print("first name:", all_results[0].get("name"))
```

## A.2. Esquema de primera fuente de datos

```
1 CREATE TABLE IF NOT EXISTS units(
2     unit_id INTEGER PRIMARY KEY,
3     unit_name VARCHAR(100) NOT NULL,
4     description TEXT
5 );
6
7 CREATE TABLE IF NOT EXISTS pollutants(
8     pollutant_id INTEGER PRIMARY KEY,
9     pollutant_name VARCHAR(100) NOT NULL
10 );
11
12 CREATE TABLE IF NOT EXISTS stations(
13     station_id INTEGER PRIMARY KEY,
14     county_id INTEGER,
15     latitude DECIMAL(9,6),
16     longitude DECIMAL(9,6),
17     FOREIGN KEY (county_id) REFERENCES counties(county_id)
18 );
19
20 CREATE TABLE IF NOT EXISTS counties(
21     county_id INTEGER PRIMARY KEY,
22     county_name VARCHAR(100) NOT NULL,
23     geometry TEXT
24 );
25
26 CREATE TABLE IF NOT EXISTS sensors(
27     sensor_id INTEGER PRIMARY KEY,
28     station_id INTEGER,
29     pollutant_id INTEGER,
30     unit_id INTEGER,
31     FOREIGN KEY (station_id) REFERENCES stations(station_id),
32     FOREIGN KEY (pollutant_id) REFERENCES pollutants(pollutant_id),
33     FOREIGN KEY (unit_id) REFERENCES units(unit_id)
34 );
35
36 CREATE TABLE IF NOT EXISTS measurements(
37     measurement_id INTEGER PRIMARY KEY,
```

```
38     sensor_id INTEGER,  
39     measurement_value DECIMAL(10,4) NOT NULL,  
40     start_time DATETIME NOT NULL,  
41     end_time DATETIME NOT NULL,  
42     FOREIGN KEY (sensor_id) REFERENCES sensors(sensor_id),  
43     UNIQUE(sensor_id, start_time, end_time)  
44 );
```

### A.3. Esquema de segunda fuente de datos

```
1 CREATE TABLE IF NOT EXISTS asthma_prevalence (
2     id INTEGER PRIMARY KEY,
3     county_id INTEGER,
4     year_from INTEGER,
5     year_to INTEGER,
6     demographic_group_id INTEGER,
7     current_prevalence FLOAT,
8     ci_95_lower FLOAT,
9     ci_95_upper FLOAT,
10    comment TEXT,
11    FOREIGN KEY (county_id) REFERENCES counties(county_id),
12    FOREIGN KEY (demographic_group_id) REFERENCES demographic_group(id)
13 );
14
15 CREATE TABLE IF NOT EXISTS grouped_counties (
16     -- Though it's a 1:N relationship, we create a separate table to allow for
17     -- easier querying and future expansion
18     county_id INTEGER,
19     asthma_prevalence_id INTEGER,
20     FOREIGN KEY (county_id) REFERENCES counties(county_id),
21     FOREIGN KEY (asthma_prevalence_id) REFERENCES asthma_prevalence(id),
22     PRIMARY KEY (county_id, asthma_prevalence_id)
23 );
24
25 CREATE TABLE IF NOT EXISTS demographic_group (
26     id INTEGER PRIMARY KEY,
27     strata TEXT,
28     age_group TEXT, -- as is from the data
29     age_min INTEGER,
30     age_max INTEGER
31 );
```

# Bibliografía

- [1] California Department of Public Health. Asthma prevalence. <https://catalog.data.gov/dataset/asthma-prevalence-6908c>, 2025. Data last modified: 2025-12-05. Metadata updated: 2025-12-23. Accessed: 2026-01-01.
- [2] Haneen Khreis, Charlotte Kelly, James Tate, Roger Parslow, Karen Lucas, and Mark Nieuwenhuijsen. Exposure to traffic-related air pollution and risk of development of childhood asthma: A systematic review and meta-analysis. *Environment International*, 100:1–31, March 2017. URL: <https://www.sciencedirect.com/science/article/pii/S0160412016307838>, doi:10.1016/j.envint.2016.11.012.
- [3] Rajen N. Naidoo. NO<sub>2</sub> increases the risk for childhood asthma: a global concern. *The Lancet Planetary Health*, 3(4):e155–e156, April 2019. URL: [https://www.thelancet.com/journals/lanplh/article/PIIS2542-5196\(19\)30059-2/fulltext](https://www.thelancet.com/journals/lanplh/article/PIIS2542-5196(19)30059-2/fulltext), doi:10.1016/S2542-5196(19)30059-2.
- [4] OpenAQ. OpenAQ documentation. <https://docs.openaq.org>. Accessed: 2026-01-01.
- [5] U.S. Census Bureau. TIGER/Line shapefiles: Counties (`tl_2025_us_county.zip`), 2025. Accessed: 2026-01-01. URL: [https://www2.census.gov/geo/tiger/TIGER2025/COUNTY/tl\\_2025\\_us\\_county.zip](https://www2.census.gov/geo/tiger/TIGER2025/COUNTY/tl_2025_us_county.zip).
- [6] U.S. Environmental Protection Agency. Health effects of ozone in patients with asthma and other chronic respiratory disease, June 2025. Last updated June 6, 2025. Accessed 2026-01-11. URL: <https://www.epa.gov/ozone-pollution-and-your-patients-health/health-effects-ozone-patients-asthma-and-other-chronic>.
- [7] World Health Organization. WHO global air quality guidelines: particulate matter (PM<sub>2.5</sub> and PM<sub>10</sub>), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide, September 2021. Guideline. Published 22 September 2021. ISBN 978-92-4-003422-8. Accessed 2026-01-01. URL: <https://www.who.int/publications/i/item/9789240034228>.