

Impacto de la Contaminación Atmosférica en los Casos de Asma en California

Grupo Morado

Julio Agüero Encinas

Fabián Camargo

Miguel Corvo Domosti

Samuel Martín Martínez

Jiaze Zhang

Enero 2026

Resumen

El crecimiento económico asociado a la industrialización y a la intensificación de la actividad urbana ha contribuido a una degradación progresiva de la calidad del aire, con efectos directos sobre la salud pública. Entre las consecuencias más relevantes se encuentra el incremento de enfermedades respiratorias y el empeoramiento de patologías preexistentes, como el asma, especialmente en entornos con alta densidad logística e industrial.

Este proyecto analiza, tomando California (EE. UU.) como caso de estudio, si los niveles de contaminación atmosférica se ajustan a las recomendaciones de las guías globales de la Organización Mundial de la Salud y, en paralelo, explora su relación con la incidencia de asma en la población. Para ello, se emplearán series históricas de calidad del aire para contaminantes clave (incluyendo materia particulada fina, ozono a nivel del suelo y dióxido de nitrógeno, entre otros), junto con datos epidemiológicos de asma desagregados por edad, género y localización. El trabajo contempla además una evaluación espacial de la cobertura de los puntos de medición, con el fin de identificar áreas donde la monitorización resulte insuficiente y proponer mejoras. Finalmente, se desarrollarán herramientas de análisis y visualización que faciliten la interpretación de patrones temporales y geográficos y apoyen un plan de seguimiento de la salud respiratoria en función de los niveles de contaminación.

Índice general

1. Aspectos generales del proyecto	4
1.1. Problemática y objetivos	4
1.1.1. Problemática	4
1.1.2. Objetivos	5
1.2. Resultados esperados	7
1.3. Requisitos generales y técnicos	8
2. Gestión del proyecto	10
2.1. Propósito y enfoque de gestión	10
2.2. Gestión del alcance	11
2.2.1. WBS como instrumento de definición del trabajo	11
2.2.2. Entregables y criterios de aceptación	11
2.3. Gestión temporal	12
2.3.1. Cronograma mediante diagrama de Gantt	12
2.3.2. Hitos y dependencias principales	13
2.4. Gestión de recursos	14
2.4.1. Roles y responsabilidades	14
2.4.2. Herramientas de gestión y colaboración	15
2.5. Control, calidad y gestión de cambios	15
2.5.1. Control y seguimiento	15
2.5.2. Gestión de calidad	15
2.5.3. Gestión de cambios	16
2.6. Gestión de riesgos	16
2.7. Presupuesto y estimación de esfuerzo (opcional)	17
2.8. Cierre del proyecto	17
3. Plan de Preservación	18
3.1. Almacenamiento	18

3.1.1.	Almacenamiento físico	18
3.2.	Gestión de los datos	19
3.2.1.	Limpieza y curación	19
3.2.2.	Metadatos	20
3.2.3.	Acceso y reutilización	20
3.3.	Seguridad	20
3.4.	Estrategia de preservación a largo plazo	21
3.4.1.	Backup	22
3.4.2.	Almacenamiento en la nube	23
4.	Fuentes de datos	24
4.1.	Datos de calidad del aire	24
4.1.1.	Geografía de California	25
4.1.2.	Descarga de datos históricos	29
4.1.3.	Procesamiento de los datos descargados	31
4.2.	Datos de prevalencia de asma en California	34
5.	Análisis exploratorio: calidad del aire y prevalencia de asma	37
5.1.	Objetivo y alcance del análisis	37
5.2.	Metodología	37
5.2.1.	Variables y agregación	37
5.2.2.	Medida de asociación y visualización	38
5.3.	Resultados	39
5.3.1.	Material particulado fino (PM _{2,5})	39
5.3.2.	Material particulado grueso (PM ₁₀)	39
5.4.	Discusión: por qué los resultados no se corresponden con lo esperado	40
5.4.1.	Limitaciones temporales y desajustes de periodicidad	40
5.4.2.	Incertidumbre de la variable de salud	41
5.4.3.	Heterogeneidad espacial y falacia ecológica	41
5.4.4.	Confusión por factores externos a la calidad del aire	41
5.4.5.	Cobertura y calidad de las mediciones de contaminantes	41
5.4.6.	Relaciones no lineales y efectos de umbral	41
5.5.	Líneas de trabajo futuro	42
6.	Conclusiones y líneas de trabajo futuro	43
6.1.	Síntesis del proyecto	43
6.2.	Cumplimiento de objetivos y entregables	43

6.3.	Conclusiones del análisis exploratorio	44
6.4.	Limitaciones principales	44
6.4.1.	Limitaciones temporales	44
6.4.2.	Incertidumbre y naturaleza del dato epidemiológico	44
6.4.3.	Agregación espacial y heterogeneidad intrarregional	45
6.4.4.	Factores externos y confusión	45
6.5.	Recomendaciones y trabajo futuro	45
6.5.1.	Extensión multianual y análisis de series temporales	45
6.5.2.	Modelos multivariantes y control de confusores	46
6.5.3.	Estructura espacial y representatividad	46
6.5.4.	Estratificación y análisis por subpoblación	46
6.6.	Reproducibilidad, publicación y preservación	46
6.7.	Cierre	47
A.	Código para la fase ETL	48
A.1.	Extracción de datos de OpenAQ	49
A.2.	Esquema de primera fuente de datos	50
A.3.	Esquema de segunda fuente de datos	52

Capítulo 1

Aspectos generales del proyecto

1.1. Problemática y objetivos

1.1.1. Problemática

En las últimas décadas, el modelo de éxito de las sociedades modernas se ha vinculado frecuentemente a la expansión económica fundamentada en la industrialización. Tradicionalmente, esta estrategia no ha prestado atención a los efectos colaterales pertinentes a la salud pública y al medio ambiente.

A medida que las ciudades se expanden y las actividades comerciales se intensifican, el impacto sobre el entorno natural se desplaza a un segundo plano, considerándose a menudo como un efecto secundario inevitable del desarrollo.

Este descuido del entorno tiene usualmente una repercusión directa y alarmante en la salud de la población. La prioridad por sostener una economía de alto rendimiento ha derivado en una degradación de la calidad del aire que respiramos. Al no prestar debidamente atención a las emisiones derivadas de estos sistemas, se han creado condiciones ambientales que no solo causan la aparición de nuevas enfermedades respiratorias, sino que agravan seriamente las ya existentes, como es el caso del asma.

En regiones con un alto desarrollo logístico e industrial, los contaminantes que actúan como detonantes de crisis respiratorias o contribuyen al desarrollo de asma en la población infantil son especialmente prevalentes.

La siguiente figura, extraído de [5], ilustra cómo aproximadamente un tercio de los casos de asma están relacionados con la exposición a largo plazo de materia particulada fina ($PM_{2.5}$):




Figura 1.1: Portada del artículo de One Earth [5]

Más concretamente, el artículo afirma que cada incremento de $10 \mu g/m^3$ en la concentración de $PM_{2.5}$ se asocia con un aumento del riesgo de:

- $\approx 21,4\%$ en niños (intervalo de confianza del 95 %: $11,4\% - 32,3\%$)
- $\approx 7,1\%$ en adultos (intervalo de confianza del 95 %: $1,6\% - 12,9\%$)

1.1.2. Objetivos

El objetivo principal del proyecto es analizar si en California (EEUU) la calidad del aire está dentro de los niveles recomendados por la OMS [9], que establecen unas recomendaciones sobre los niveles de materia particulada, ozono, óxidos de nitrógeno, azufre y monóxido de carbono. Esto se manifiesta en límites horarios, octo-horarios, diarios y anuales.

Para este proyecto, son de especial interés los siguientes contaminantes:

- **Dióxido de nitrógeno (NO_2)**

Ciertos estudios lo relacionan con un aumento del riesgo en el desarrollo de asma durante la infancia, como [4].)

También se ha observado lo mismo en adultos, aunque con mayor heterogeneidad en los resultados [3].

Si bien en este último estudio se reconoce que las conclusiones son limitadas, puesto que muchos estudios se apoyan en asma definida por cuestionarios y no en diagnósticos clínicos, entre otros factores.

- **Materia particulada fina** ($PM_{2,5}$ y PM_{10})

Su exposición aumenta el riesgo de desarrollo de asma en la infancia.

En el caso de $PM_{2,5}$ es más homogéneo y exacerbado a partir de los 6 años continuados de exposición.

En el caso de PM_{10} se ha observado un aumento del riesgo en todos los grupos de edad [3].

- **Ozono (O_3) a nivel del suelo**

Debido a la reducción en capacidad pulmonar de los pacientes asmáticos, tras la exposición a este contaminante, se ha observado un aumento en las crisis asmáticas y en las hospitalizaciones relacionadas con el asma [8].

Objetivos específicos

Para alcanzar el objetivo principal, se plantean los siguientes objetivos específicos:

- Recopilar y procesar datos históricos de calidad del aire en California, centrándose en los contaminantes mencionados anteriormente.
- Evaluar la cobertura espacial de los puntos de medición existentes y proponer la instalación de nuevos puntos en áreas con deficiencias de monitorización.
- Analizar la relación entre los niveles de contaminación atmosférica y la incidencia de asma en la población de California, desglosada por edad, género y ubicación geográfica.
- Desarrollar herramientas de análisis y visualización que faciliten la interpretación de los resultados y permitan identificar patrones temporales y geográficos.
- Proponer un plan para monitorizar la salud respiratoria de la población en función de los niveles de contaminación atmosférica.

1.2. Resultados esperados

Los resultados esperados se pueden resumir en los siguientes puntos:

1. Informe detallado sobre la calidad del aire en California

Elaboración de un informe exhaustivo que detalle los niveles de los contaminantes analizados, comparándolos con las recomendaciones de la OMS y destacando las áreas con mayores deficiencias.

Además, relacionarlo con la incidencia de asma en la población, identificando posibles correlaciones y tendencias. Evaluar su impacto en la salud pública.

2. Análisis de la cobertura de monitorización

Evaluación de la distribución geográfica de los puntos de medición de calidad del aire en California, identificando áreas con deficiencias en la monitorización y proponiendo la instalación de nuevos puntos en dichas zonas.

3. Modelo predictivo de ingresos hospitalarios por asma

Desarrollo de un modelo predictivo que relacione los niveles de contaminación atmosférica con la incidencia de asma en la población, con el fin de anticipar posibles crisis sanitarias y planificar recursos médicos.

4. Base de datos integrada

Creación de una base de datos integrada que combine datos de calidad del aire y datos epidemiológicos, facilitando futuros análisis y estudios. Junto con flujo de trabajo reproducible para la actualización periódica de los datos.

5. Base científica para políticas públicas en California

Proporcionar una base científica sólida que respalde la formulación de políticas públicas destinadas a mejorar la calidad del aire y la salud respiratoria de la población en California.

Este último punto es especialmente relevante, ya que los resultados del proyecto pueden influir en la toma de decisiones políticas, promoviendo medidas que reduzcan la contaminación atmosférica y mejoren la calidad de vida de los habitantes de California.

1.3. Requisitos generales y técnicos

Para llevar a cabo este proyecto, se requieren los siguientes recursos y condiciones:

1. Datos

Se requiere acceso a bases de datos históricas de calidad del aire en California, que incluyan mediciones de los contaminantes de interés en cada condado de California. Los datos deben estar preferiblemente tomados horariamente, puesto que a partir de ello se pueden computar varias métricas por las que se rige la normativa de la OMS (diarias, octo-horarias, anuales, etc.).

Similarmente, se requieren datos de prevalencia de asma en California por condado. Es de interés que los datos incluyan agregación por edad, puesto que varios estudios enfocan sus conclusiones en desarrollo de asma en la infancia. Además, es deseable que los datos incluyan un intervalo de confianza, puesto que la prevalencia de asma se suele estimar a partir de encuestas, y no es factible conducir un censo exhaustivo.

2. Herramientas y software

Se utilizarán herramientas de análisis de datos y visualización, como Python con bibliotecas especializadas (pandas, geopandas, etc.). Se emplearán cuadernos de Jupyter para documentar el proceso ETL (Extracción, Transformación y Carga) y los análisis realizados. Para la elaboración de gráficos y mapas, se emplearán herramientas como Power BI o QGIS. Los datos se transformarán a una base de datos SQLite para facilitar su consulta y análisis, con la posibilidad de extender a otros sistemas de gestión de bases de datos si el volumen de datos lo requiere.

3. Recursos humanos

Se requieren los siguientes perfiles profesionales para desarrollar el proyecto:

- **Científico de datos**

Responsable de la recopilación, procesamiento y análisis de los datos, así como del desarrollo de modelos predictivos.

- **Especialista en salud pública**

Proporcionará conocimientos sobre la epidemiología del asma y su relación con la contaminación atmosférica.

- **Visualizador de datos**

Encargado de diseñar y crear visualizaciones efectivas que faciliten la interpretación de los resultados.

- **Técnico GIS**

Responsable del análisis espacial de los datos y de la evaluación de la cobertura de monitorización.

- **Gestor de proyectos**

Encargado de coordinar las actividades del equipo, gestionar los plazos y asegurar el cumplimiento de los objetivos.

4. **Recursos materiales**

Se requiere acceso a equipos informáticos con capacidad suficiente para manejar grandes volúmenes de datos y realizar análisis complejos. Para concretar los requisitos de hardware, se evaluará el volumen de datos a procesar y la complejidad de los análisis previstos conjuntamente con el científico de datos. Para garantizar un entorno de trabajo colaborativo, se utilizarán plataformas de gestión de proyectos y almacenamiento en la nube.

5. **Organización cronológica**

El proyecto se desarrollará en varias fases, cada una con sus propios hitos y entregables que se deberán discutir detalladamente con el gestor de proyectos y el equipo involucrado. Esto irá acompañado de la elaboración de un presupuesto detallado para evitar demoras y sobrecostes.

Capítulo 2

Gestión del proyecto

2.1. Propósito y enfoque de gestión

El proyecto *Impacto de la calidad del aire en la prevalencia de asma en California* combina adquisición masiva de datos por API, curación, análisis estadístico/espacial, modelado predictivo e interpretación de resultados con posibles implicaciones para salud pública. Este tipo de iniciativas presenta dos retos de gestión típicos: (i) **heterogeneidad** de fuentes y formatos (tabular, geoespacial, series temporales), y (ii) **iteración** inevitable en la construcción de *pipelines* reproducibles.

Para responder a estos retos, la gestión se apoya en:

- **Estructura de desglose del trabajo (WBS)**: define el alcance mediante fases y paquetes de trabajo.
- **Cronograma (Gantt)**: convierte la WBS en un plan temporal con dependencias e hitos.
- **Control y seguimiento transversal**: mecanismos de coordinación, trazabilidad, calidad y mitigación de riesgos.

El enfoque adoptado es **secuencial por fases**, pero con **iteración controlada** dentro de cada fase. En particular, la adquisición y curación de datos se ejecutan de manera incremental (descarga parcial, almacenamiento intermedio, re-ejecución de procesos) para evitar pérdidas de progreso y para facilitar la depuración del flujo de trabajo.

2.2. Gestión del alcance

2.2.1. WBS como instrumento de definición del trabajo

La WBS organiza el proyecto en fases que recorren el ciclo completo de los datos, desde la planificación hasta el cierre. Su objetivo principal es:

- **Delimitar el alcance** (qué se hace y qué queda fuera).
- **Asegurar trazabilidad** entre objetivos, datos, análisis y resultados.
- **Facilitar el control** del avance y la evaluación del rendimiento.

La Figura 2.1 presenta la WBS del proyecto, estructurada en fases y paquetes de trabajo.




Figura 2.1: Work Breakdown Structure (WBS) del proyecto por fases y paquetes de trabajo.

2.2.2. Entregables y criterios de aceptación

Para asegurar una entrega verificable, se definen entregables alineados con las fases principales:

- **E1. Documento de objetivos y requisitos:** objetivos generales/específicos, alcance geográfico/temporal y criterios de calidad.
- **E2. Pipeline de adquisición:** scripts para descarga automática, control de versiones de datos brutos y registro de ejecución.
- **E3. Base de datos integrada:** esquema lógico y base de datos que permita consultas conjuntas (calidad del aire + asma).

- **E4. Dataset curado + metadatos:** normalización, control de faltantes, tratamiento de valores atípicos y documentación.
- **E5. Análisis y visualizaciones:** resultados de correlación/tendencias y paneles/gráficas reproducibles.
- **E6. Modelo predictivo:** modelos base y específicos, evaluación comparativa e interpretabilidad.
- **E7. Evaluación de cobertura:** diagnóstico de estaciones/sensores, puntos críticos y deficiencias por contaminante.
- **E8. Publicación y cierre:** informe final, repositorio público con código/datos, y evaluación final del proyecto.

Los criterios de aceptación se basan en:

- **Reproducibilidad:** ejecución de scripts/cuadernos con resultados coherentes (mismas entradas → mismas salidas).
- **Trazabilidad:** cada figura/tabla relevante vinculada a un procedimiento de generación (script o notebook).
- **Calidad de datos:** reglas explícitas (completitud mínima, coherencia temporal, consistencia geográfica, etc.).

2.3. Gestión temporal

2.3.1. Cronograma mediante diagrama de Gantt

El cronograma traduce la WBS a tareas calendarizadas, incorporando dependencias y hitos (*milestones*). Este instrumento permite:

- visualizar **solapes** y **dependencias** entre fases (p. ej., curación y análisis),
- identificar **camino crítico** (tareas cuya demora desplaza el fin del proyecto),
- y programar **revisiones** de avance orientadas a entregables.

La Figura 2.2 muestra el diagrama de Gantt del proyecto.




Figura 2.2: Cronograma del proyecto (diagrama de Gantt) con fases, tareas e hitos principales.

2.3.2. Hitos y dependencias principales

A nivel de gestión, se establecen hitos de control que marcan “puntos de no retorno” del proyecto:

- **Hito de planificación:** requisitos, KPIs y alcance validados.
- **Hito de *pipeline* de datos:** adquisición y curación automatizadas con almacenamiento estable.
- **Hito de modelado:** modelos evaluados y seleccionados, con interpretación documentada.

- **Hito de publicación:** resultados consolidados, repositorio público y memoria final.

Las dependencias clave suelen ser:

- La **curación** depende de una adquisición estable (datos brutos disponibles y versionados).
- El **análisis** depende de la curación (sin reglas de limpieza, los hallazgos no son defendibles).
- El **modelado** depende de la integración (base de datos o dataset final con variables consistentes).
- La **evaluación de cobertura** depende de disponer de estaciones/sensores georreferenciados por condado.

2.4. Gestión de recursos

2.4.1. Roles y responsabilidades

El proyecto requiere perfiles complementarios para cubrir la cadena completa (adquisición, curación, análisis, GIS, comunicación y coordinación). Se adopta una organización con responsabilidades explícitas y revisión por pares en los componentes críticos.

A modo de síntesis, la Tabla 2.1 presenta una matriz RACI (Responsible, Accountable, Consulted, Informed) para las actividades principales.

Actividad	CD	SP	VD	GIS
Definición de requisitos y KPIs	A/R	C	C	C
Adquisición de datos (scripts/API)	A/R	C	I	C
Curación e integración (BD/datasets)	A/R	C	I	C
Análisis estadístico y temporal	A/R	C	C	C
Análisis geoespacial y cobertura	R	C	I	A/R
Modelado predictivo e interpretabilidad	A/R	C	C	I
Redacción, visualizaciones y publicación	C	C	A/R	C
Seguimiento de plazos y coordinación	A/R ¹	I	I	I

Cuadro 2.1: Matriz RACI simplificada. CD: Científico de datos; SP: Especialista en salud pública; VD: Visualizador de datos; GIS: Técnico GIS.

¹El rol de gestor de proyectos puede recaer en el propio científico de datos o estar separado, según disponibilidad. En ambos casos, la coordinación y control de plazos debe tener un responsable único.

2.4.2. Herramientas de gestión y colaboración

Para garantizar coordinación y trazabilidad se emplean:

- **Control de versiones:** repositorio para código, documentación y cambios relevantes.
- **Seguimiento de tareas:** incidencias (*issues*), tablero Kanban o lista de hitos por fase.
- **Ejecución reproducible:** cuadernos y scripts versionados con entornos documentados.
- **Almacenamiento:** separación entre datos brutos, intermedios y curados; copias de seguridad.

2.5. Control, calidad y gestión de cambios

2.5.1. Control y seguimiento

El control se realiza mediante revisiones periódicas centradas en hitos y entregables. En cada revisión:

- se verifica el **estado** de tareas críticas,
- se registran **bloqueos** (técnicos o de datos),
- y se acuerdan **acciones** con responsables y fecha objetivo.

Como soporte cuantitativo, se definen KPIs de gestión simples, por ejemplo:

- **Cumplimiento de hitos:** porcentaje de hitos logrados en fecha.
- **Automatización:** proporción de tareas de adquisición/curación ejecutables sin intervención manual.
- **Calidad de datos:** métricas de completitud, consistencia y porcentaje de registros válidos tras curación.

2.5.2. Gestión de calidad

La calidad se aborda desde dos perspectivas:

- **Calidad de datos:** reglas explícitas (validación de rangos, tratamiento de faltantes, detección de atípicos).
- **Calidad del proceso:** revisión por pares, trazabilidad de cambios y reproducibilidad (misma entrada $\rightarrow$ misma salida).

2.5.3. Gestión de cambios

Dado que los proyectos de datos evolucionan con el descubrimiento de problemas (p. ej., sesgos, faltantes, cambios en endpoints), los cambios se gestionan con un flujo sencillo:

1. **Registro:** descripción del cambio y motivación.
2. **Impacto:** evaluación del efecto en alcance/tiempo/calidad.
3. **Aprobación:** validación por el responsable del proyecto.
4. **Implementación:** ejecución y documentación; actualización de scripts y metadatos.

2.6. Gestión de riesgos

La Tabla 2.2 resume riesgos habituales del proyecto y su tratamiento.

Riesgo	Prob.	Impacto	Mitigación / contingencia
Límites de la API y cuellos de botella en descarga	Media	Alto	Descarga incremental, pausas automáticas, almacenamiento intermedio; reintentos y registro de fallos.
Calidad insuficiente (faltantes/atípicos)	Media	Alto	Reglas de curación documentadas; validación por etapas; informes de calidad; sensibilidad de resultados.
Incompatibilidad temporal/geográfica entre fuentes	Media	Alto	Estandarización de granularidad; claves de integración; comprobaciones de consistencia; trazabilidad de transformaciones.
Sesgos por cobertura de estaciones/sensores	Alta	Medio	Evaluación de cobertura por condado/contaminante; análisis de robustez; explicitar limitaciones en discusión.
Pérdida o corrupción de datos/código	Baja	Muy alto	Copias de seguridad, control de versiones, hashes de integridad, y repositorio remoto para recuperación.
Retrasos por complejidad del modelado	Media	Medio	Modelos base tempranos; iteración incremental; priorizar interpretabilidad y valor analítico sobre complejidad innecesaria.

Cuadro 2.2: Registro de riesgos: probabilidad, impacto y medidas de mitigación/contingencia.

2.7. Presupuesto y estimación de esfuerzo (opcional)

Si se requiere una estimación económica, puede derivarse del esfuerzo por paquete de trabajo:

$$C = H \cdot r + C_{\text{infra}},$$

donde H son horas totales estimadas, r una tarifa media por hora, y C_{infra} recoge costes de infraestructura (almacenamiento, licencias si aplican, etc.). Para mantener coherencia con la gestión temporal, es recomendable estimar H por fase/hito (según WBS/Gantt) y revisar la estimación tras completar los primeros entregables (planificación y *pipeline* inicial).

2.8. Cierre del proyecto

El cierre contempla:

- **Verificación de entregables:** informe final, anexos técnicos y repositorio reproducible.
- **Publicación:** datos curados y código con licencia adecuada, y archivado en repositorio de larga duración.
- **Lecciones aprendidas:** incidencias principales, decisiones metodológicas y mejoras para iteraciones futuras.

Este conjunto de prácticas asegura que el proyecto no solo concluya con resultados analíticos, sino también con activos reutilizables (datos, código, documentación) y una base sólida para extensiones o replicaciones posteriores.

Capítulo 3

Plan de Preservación

El presente Plan de Preservación tiene como objetivo garantizar la integridad, disponibilidad y reutilización a largo plazo de los activos digitales generados en el proyecto *Impacto de la Contaminación Atmosférica en los Casos de Asma en California*. Dado que el estudio maneja series temporales críticas y datos de salud pública, se ha diseñado una estrategia que cubre desde el almacenamiento físico hasta la gestión de derechos de acceso, alineándose con los principios FAIR (*Findable, Accessible, Interoperable, Reusable*).

3.1. Almacenamiento

La estrategia de almacenamiento se ha diseñado teniendo en cuenta el volumen de los datos geo-espaciales y la necesidad de diferenciar claramente entre los datos de uso frecuente y los archivos destinados a la preservación estática.

3.1.1. Almacenamiento físico

La infraestructura física local constituye el primer nivel de nuestra jerarquía de datos. Debido a la carga computacional que requieren las operaciones espaciales en **ArcGIS Pro** —especialmente el cruce de capas vectoriales de códigos postales (ZCTA) con las series temporales de contaminantes—, hemos priorizado el rendimiento en los equipos de trabajo.

Para el **almacenamiento activo**, utilizamos unidades de estado sólido (**SSD**) en las estaciones de trabajo locales. Esto nos permite evitar cuellos de botella durante la renderización de mapas y la ejecución de los scripts de limpieza en R. Adicionalmente, mantenemos un nivel de **almacenamiento en frío** (*cold storage*) mediante discos duros externos mecánicos (**HDD**) de alta capacidad. En estos dispositivos se custodian las copias originales de los *raw*

data descargados de la EPA y *catalog.data.gov*, liberando espacio en los discos de trabajo principales y sirviendo como repositorio local de los datos fuente inalterados.

3.2. Gestión de los datos

El presente estudio se adhiere a los principios FAIR (Findable, Accessible, Interoperable, Reusable) para garantizar la transparencia y la reproducibilidad de la investigación. La gestión de la información no se limita a la recolección, sino que abarca la totalidad del ciclo de vida de los datos, estableciendo procedimientos claros para su manejo desde la obtención inicial hasta su preservación a largo plazo.

3.2.1. Limpieza y curación

La transformación de los datos brutos en información analizable se ha llevado a cabo mediante un flujo de trabajo reproducible ejecutado en el entorno estadístico **R**. En lugar de correcciones manuales, que son propensas a errores y difíciles de auditar, hemos desarrollado scripts automatizados utilizando la librería **tidyverse** para estandarizar los formatos de fecha y unificar las unidades de medida de los contaminantes (NO_2 , O_3) a partes por millón (ppm).

Para el tratamiento de inconsistencias, los scripts aplican reglas de validación lógica que identifican registros duplicados y valores fuera de rango. Específicamente, la detección de *outliers* en las lecturas de los sensores se realiza mediante el cálculo del rango intercuartílico (IQR), filtrando automáticamente aquellas mediciones que exceden el umbral de $1,5 \times IQR$ por considerarse errores instrumentales. Respecto a los valores nulos (NaNs) en las series temporales, cuando los huecos de información son inferiores a 4 horas, se imputan mediante algoritmos de interpolación lineal disponibles en el paquete **zoo**, garantizando la continuidad de la serie sin introducir sesgos significativos.

Por último, la integridad espacial de los datos se verifica utilizando **ArcGIS Pro**. Antes de realizar el cruce espacial entre las estaciones de monitoreo y los códigos postales (ZCTA), empleamos las herramientas de topología de ArcGIS para asegurar que las geometrías de los *shapefiles* no presentan superposiciones ni huecos que pudieran alterar la asignación de los niveles de exposición.

3.2.2. Metadatos

Para facilitar la recuperación e interpretación de los datos por terceros, se ha adoptado el esquema de metadatos estandarizado **Dublin Core**. La elección de este estándar internacional permite describir los recursos digitales mediante un conjunto de elementos esenciales —tales como Título, Creador, Cobertura Espacial, Fecha y Formato—, garantizando que el contexto de recolección y las características técnicas del *dataset* sean comprensibles sin ambigüedades para la comunidad científica.

Como parte fundamental de esta documentación, se adjunta un diccionario de datos o *codebook* detallado que define explícitamente cada variable, especifica las unidades de medida empleadas (ej. ppm o $\mu\text{g}/\text{m}^3$) y desglosa el significado de cualquier codificación utilizada en las tablas. Adicionalmente, para asegurar el orden, todos los archivos siguen una convención de nombrado sistemática (ej. YYYYMMDD_Nombre_v01) que facilita la identificación rápida de versiones.

3.2.3. Acceso y reutilización

Una vez finalizado el estudio, los datos procesados se depositarán en el repositorio de acceso abierto **Zenodo**, gestionado por el CERN. Esta plataforma asignará automáticamente un Identificador de Objeto Digital (DOI) único al conjunto de datos, asegurando que sea localizable y citable de manera permanente en futuras investigaciones.

Los datos se distribuirán bajo la licencia **Creative Commons Atribución 4.0 Internacional (CC-BY 4.0)**. Esta licencia abierta fomenta la reutilización, permitiendo a terceros compartir y adaptar el material para cualquier propósito, incluso comercial, con la única condición de reconocer la autoría original. En cuanto a las consideraciones éticas, al trabajar con datos de prevalencia agregados a nivel de condado y no con historias clínicas individuales, se garantiza la privacidad de los pacientes sin necesidad de aplicar técnicas adicionales de anonimización sobre los resultados finales.

3.3. Seguridad

La seguridad de la información en este proyecto se ha abordado desde una perspectiva integral que contempla tanto la integridad de los ficheros como la privacidad de los datos sensibles, aspectos críticos cuando se trabaja con información relacionada con la salud pública. Aunque los datos de prevalencia de asma utilizados son agregados y no contienen información per-

sonal identificable (PII) de pacientes individuales, hemos aplicado protocolos estrictos para evitar cualquier riesgo de reidentificación o manipulación malintencionada de los resultados.

En primer lugar, garantizamos la integridad de los datos mediante el uso de funciones de resumen o *hashing*. Cada vez que se descarga un conjunto de datos original de las fuentes gubernamentales o se genera un *dataset* consolidado tras la limpieza, se calcula su huella digital. Esto nos permite verificar periódicamente que los archivos almacenados en nuestros discos locales no han sufrido alteraciones silenciosas, conocidas como *bit rot*, ni modificaciones accidentales durante su manipulación. Si la suma de verificación actual no coincide con la registrada originalmente, el sistema nos alerta para restaurar una copia limpia desde el sistema de copias de seguridad.

Por otro lado, el control de acceso a los datos en fase de desarrollo se gestiona mediante permisos estrictos en el repositorio de código. Hemos establecido una política de roles donde únicamente los miembros del equipo de investigación tienen permisos de escritura y modificación sobre los *scripts* de análisis y los datos brutos. Cualquier cambio en el código que procesa los datos de contaminación o salud debe pasar por una revisión por pares antes de ser fusionado con la rama principal del proyecto. Esta trazabilidad completa nos asegura que ningún dato ha sido alterado de forma arbitraria para forzar una correlación estadística inexistente, manteniendo así la ética y la validez científica del estudio.

Finalmente, para el tránsito de información entre los equipos locales y los sistemas de almacenamiento remoto, utilizamos exclusivamente protocolos cifrados. Tanto la sincronización con la nube institucional como las operaciones de confirmación de cambios en el repositorio de código se realizan a través de canales seguros HTTPS y SSH, protegiendo la propiedad intelectual del proyecto y los datos de posibles interceptaciones en redes no seguras.

3.4. Estrategia de preservación a largo plazo

La preservación digital a largo plazo es un desafío que va más allá del simple almacenamiento de archivos; implica asegurar que la información permanezca legible, comprensible y ejecutable a medida que la tecnología evoluciona. Nuestra estrategia se fundamenta en la migración proactiva de formatos y la documentación exhaustiva, con el objetivo de que este estudio sobre el asma en California pueda ser reproducido con exactitud dentro de diez o veinte años, independientemente del software que exista en ese momento.

Una de las decisiones más importantes que hemos tomado para garantizar esta perdurabilidad

es la renuncia al uso de formatos propietarios para el archivo definitivo. Aunque durante la fase activa del proyecto utilizamos formatos nativos de Excel o archivos de proyecto de ArcGIS Pro por su eficiencia operativa, somos conscientes de que estos formatos podrían quedar obsoletos o requerir licencias de software costosas en el futuro. Por ello, nuestra política de preservación dicta que todo activo digital debe tener una versión equivalente en un estándar abierto:

- **Datos tabulares:** Se convierten a **CSV** con codificación UTF-8, asegurando su legibilidad por cualquier editor de texto básico.
- **Datos geográficos:** La cartografía vectorial se exporta a **GeoJSON**, un formato basado en texto y ampliamente soportado.
- **Documentación:** La memoria y los manuales se archivan en **PDF/A**, el estándar ISO diseñado específicamente para el archivo a largo plazo que incrusta todas las fuentes y elementos visuales necesarios.

3.4.1. Backup

Para mitigar el riesgo de pérdida catastrófica de datos, ya sea por fallos de hardware, errores humanos o ataques de software malicioso, hemos implementado una política de copias de seguridad rigurosa basada en el estándar de la industria conocido como la regla **3-2-1**.

Esta metodología asegura que no exista un único punto de fallo que pueda comprometer la totalidad del proyecto.

El protocolo establecido dicta que debemos mantener en todo momento al menos **tres** copias completas de todos los datos, almacenadas en **dos** soportes de diferente naturaleza, con **una** copia ubicada fuera de sitio (*off-site*):

1. **Copia de Trabajo:** Reside en las unidades SSD locales para el procesamiento diario.
2. **Copia de Seguridad Local (Air Gap):** Se realiza semanalmente en los discos duros externos (HDD). La característica clave de esta copia es su aislamiento: los discos se mantienen **desconectados física y lógicamente** de la red y de la corriente eléctrica cuando no se está realizando la copia. Esta técnica, conocida como “brecha de aire” (*air gap*), proporciona nuestra defensa más robusta contra el *ransomware*, ya que es físicamente imposible que un software malicioso encripte una unidad que no está conectada al sistema infectado.
3. **Copia Remota:** Se almacena en la nube institucional, asegurando la recuperación ante desastres físicos en el lugar de trabajo, como incendios o robos.

3.4.2. Almacenamiento en la nube

El almacenamiento en la nube juega un doble rol fundamental en nuestro proyecto: facilita la colaboración distribuida durante la fase activa y actúa como repositorio final para la preservación estática.

Durante el desarrollo, utilizamos **Google Drive/OneDrive** (vinculados a cuentas institucionales) y **GitHub** para la sincronización inmediata de documentos y código entre los miembros del equipo. Sin embargo, para la preservación a largo plazo, dependemos de **Zenodo**. La elección de este repositorio del CERN no es trivial: a diferencia de las nubes comerciales que requieren pagos recurrentes o mantenimiento de cuentas activas, Zenodo garantiza la preservación de los archivos científicos durante al menos 20 años, asegurando que la evidencia generada en este estudio permanezca accesible a la comunidad científica de manera perpetua.

Capítulo 4

Fuentes de datos

En este capítulo se describen las fuentes de datos utilizadas en el análisis del impacto de la contaminación atmosférica en los casos de asma en California.

Se detallan las características de cada conjunto de datos, su origen, y cómo se integran en el estudio. En este estudio se han empleado principalmente dos fuentes de datos:

- Datos de calidad del aire obtenidos de la iniciativa **OpenAQ**.
- Datos de prevalencia de asma en la población californiana proporcionados por **data.gov**, la plataforma de datos abiertos del gobierno de Estados Unidos.

Para la extracción y filtrado de los datos, se han realizado una serie de tareas que se describirán en detalle en las secciones siguientes.

Todo este proceso ha sido recogido en un cuaderno de Jupyter, que se puede localizar en el repositorio del proyecto [2], en la ruta `code/ETL Source I.ipynb`.

A lo largo de las secciones, se facilitarán algunas capturas de pantalla de fragmentos del cuaderno para ilustrar ciertas partes del proceso.

4.1. Datos de calidad del aire

Los datos de calidad del aire se han obtenido de la iniciativa **OpenAQ**, que proporciona acceso abierto a mediciones de contaminantes atmosféricos a nivel global.

Entre otros contaminantes, las entidades colaboradoras exponen datos sobre niveles de dióxido de nitrógeno (NO_2), ozono (O_3) y material particulado fino ($PM_{2.5}$), que son relevantes para el estudio del asma.

Además de ofrecer un visor web, **OpenAQ** cuenta con una API que permite la descarga programática de datos históricos y en tiempo real. En la documentación oficial de la API se detallan los *endpoints* disponibles, los parámetros de consulta y los formatos de respuesta.

En concreto, es de particular relevancia el hecho de que la API tiene un límite de peticiones para distintas franjas temporales. En el caso de California, ha sido de relevancia considerar los siguientes límites, cuyas razones revelaremos más adelante:

- 60 peticiones por minuto.
- 2000 peticiones por hora.

Estas restricciones han sido el principal cuello de botella a la hora de descargar grandes volúmenes de datos históricos.

4.1.1. Geografía de California

Los datos expuestos por el gobierno de Estados Unidos están desglosados por condados, que son las subdivisiones administrativas de primer nivel dentro de los estados.

Esto es de relevancia, puesto que las estaciones de medición de calidad del aire exponen su ubicación geográfica en coordenadas de latitud y longitud (EPSG:4326), por lo que es necesario asignar cada estación a su condado correspondiente.

Para este cometido, se han realizado dos tareas principales:

- **Obtener los límites geográficos de los condados de California.**

Para ello, se han empleado los datos de *shapefiles* proporcionados por el *U.S. Census Bureau* [7]. Estos archivos contienen la geometría de los condados, que se ha utilizado para determinar si una estación de medición se encuentra dentro de un condado específico.

- **Filtrar las estaciones de medición mediante un bbox**

(*bounding box*, i.e., un rectángulo delimitador) que englobe toda California, puesto que la API de **OpenAQ** permite filtrar por este criterio.

A continuación se muestra el código empleado para descargar los shapefiles de los condados:

```
1
2 import requests
3 from pathlib import Path
```

```

4 # download county shapefiles from US Census Bureau
5 shapes_url =
    ↪ 'https://www2.census.gov/geo/tiger/TIGER2025/COUNTY/tl_2025_us_county.zip'
6 geo_dir = Path("data/geographical")
7 geo_dir.mkdir(parents=True, exist_ok=True)
8 shapes_path = geo_dir / "tl_2025_us_county.zip"
9 if not shapes_path.exists():
10     print(f"Downloading county shapefiles from {shapes_url}...")
11     r = requests.get(shapes_url)
12     with open(shapes_path, 'wb') as f:
13         f.write(r.content)
14     print(f"Downloaded to {shapes_path}")
15 else:
16     print(f"Shapefiles already exist at {shapes_path}")
17

```

El archivo comprimido descargado se encuentra en la ruta `data/geographical/tl_2025_us_county.zip`, cuya versión descomprimida se halla en la sub-carpeta `california_counties`; en caso de que el lector desee explorar los archivos.

En la Figura 4.1 se muestra una captura de pantalla de los condados de Estados Unidos visualizados en QGIS, un software de sistemas de información geográfica (*GIS*).

Los condados de California están resaltados en rosa.

Son de particular interés las siguientes columnas:

- **STATEFP**: código FIPS del estado (California es 06).
- **NAME**: nombre del condado, valor que empleamos para relacionarlo con los datos de asma.
- **geometry**: geometría del condado en formato poligonal, es decir, una cadena de texto en formato WKT (*Well-Known Text*).

Se facilita un ejemplo ilustrativo en la Figura 4.2.

Para procesar estos datos geográficos, se ha empleado la librería `geopandas`, que extiende las funcionalidades de `pandas` para manejar datos espaciales.

En concreto, nos permite usar el método `Polygon.contains()` para determinar si las coordenadas de una estación de medición están dentro de la geometría de un condado.




Figura 4.1: Visualización de condados en QGIS

1 POLYGON ((-122.373121 37.883884, -122.371142 37.884364, ...))

Figura 4.2: Ejemplo: geometría en WKT (ilustrativo)

Una vez que tenemos definido el flujo a seguir para clasificar las estaciones por condado, procedemos a exponer la cuestión de decidir cómo filtrar las estaciones de interés a través de la API de `OpenAQ`.

Como ya se ha mencionado, la API permite filtrar las estaciones mediante un *bounding box*, que se define por las coordenadas de sus esquinas suroeste y noreste.

Para California, simplemente se ha usado QGIS para obtener unas coordenadas aproximadas que engloban todo el estado. En la Figura 4.3 se muestra una captura de pantalla de QGIS donde se procede a copiar las coordenadas.




Figura 4.3: Obtención del bbox de California en QGIS

Se puede consultar el código empleado en la Sección A.1.

Posteriormente, estos datos se han procesado para asignar cada estación a su condado correspondiente, como se ha descrito anteriormente.

Se proporciona una tabla con la distribución de estaciones por condado en California (se ha mostrado solo los 10 primeros condados ordenados por recuento) en la Tabla 4.1.

Cuadro 4.1: Recuento por condado

Condado	Recuento
Los Angeles	403
Alameda	190
Mono	94
Contra Costa	87
Sacramento	83
San Francisco	66
Monterey	50
Sonoma	48
San Diego	46
San Luis Obispo	44

4.1.2. Descarga de datos históricos

Ahora que tenemos los datos de las estaciones de interés, el siguiente paso es realizar una petición a la API de **OpenAQ** para descargar los datos históricos de calidad del aire.

La documentación oficial de la API se puede consultar en la fuente [6].

La API devuelve información sobre los sensores de cada estación, que miden distintos contaminantes atmosféricos.

A partir de esto, se ha diseñado un bucle que itera sobre los 5333 sensores identificados en California, empleando el *endpoint* **/sensors** de la API.

Dado que la API impone límites en el número de peticiones por minuto y por hora, se ha implementado una lógica para monitorizar las cabeceras de respuesta **X-Rate-Limit-Remaining** y pausar las peticiones cuando sea necesario.

Este proceso ha tenido una naturaleza iterativa en cuanto al código, puesto que han surgido varios inconvenientes durante la descarga masiva de datos.

Sin embargo, puesto que se han guardado los datos descargados en archivos intermedios, no se ha perdido el progreso realizado hasta el momento.

Es por esta razón que la barra de progreso muestra un tiempo estimado menor del real.

Teniendo en cuenta los límites impuestos por la API, se estima que la descarga completa de los datos históricos de calidad del aire en California lleva entre 2 y 3 horas.

Se adjunta una captura de pantalla en la Figura 4.4 que ilustra el progreso de la descarga.

```

# The API has a rate limit of 60 per minute and 2000 per hour.
from tqdm import tqdm
import time, requests

SENSOR_BASE = "https://api.openaq.org/v3/sensors"
aq_data_path = Path("data/openaq_data")
aq_data_path.mkdir(parents=True, exist_ok=True)
pbar = tqdm(total=selected_stations['sensors_count'].sum())
headers = {"X-API-Key": API_KEY}
for _, row in selected_stations.iterrows():
    station = row
    sensors_list = json.loads(row['sensors'].replace("'", ''))
    for sensor in sensors_list:
        # check if sensor data file already exists
        sensor_filename = aq_data_path / "sensors" / f"sensor_{sensor['id']}.json"
        if sensor_filename.exists():
            pbar.update(1)
            continue
        sensor_id = sensor['id']
        r = requests.get(
            f"{SENSOR_BASE}/{sensor_id}/measurements",
            headers=headers,
            timeout=60,
            params={
                "date_from": "2015-01-01T00:00:00+00:00",
                "date_to": "2024-12-31T23:59:59+00:00",
            }
        )
        if r.headers.get('X-RateLimit-Remaining') == '0':
            reset_time = int(r.headers.get('X-RateLimit-Reset', 60))
            pbar.set_description(f"Rate limit reached. Sleeping for {reset_time + 1} seconds...")
            time.sleep(reset_time + 1)
            r = requests.get(
                f"{SENSOR_BASE}/{sensor_id}/measurements",
                headers=headers,
                timeout=60,
                params={
                    "date_from": "2015-01-01T00:00:00+00:00",
                    "date_to": "2024-12-31T23:59:59+00:00",
                }
            )
        sensor_data = r.json().get("results", {})
        # save sensor data to file
        sensor_file_path = aq_data_path / "sensors" / f"sensor_{sensor_id}.json"
        with open(sensor_file_path, 'w') as f:
            json.dump(sensor_data, f, indent=4)
        pbar.set_description(f"Saved sensor data to {sensor_file_path}")
        # append to metadata dataframe
        pbar.update(1)
        if r.headers.get('X-RateLimit-Remaining') == '0':
            reset_time = int(r.headers.get('X-RateLimit-Reset', 60))
            pbar.set_description(f"Rate limit reached. Sleeping for {reset_time + 1} seconds...")
            time.sleep(reset_time + 1)
pbar.close()

```

Saved sensor data to data/openaq_data/sensors/sensor_14949145.json: 100% |██████████| 5333/5333 [43:04<00:00, 2.06it/s]

Figura 4.4: Celda del cuaderno ilustrando las peticiones

Puesto que se han guardado los datos descargados en archivos JSON individuales, se ha optado por comprimirlos en un archivo ZIP para facilitar su manipulación posterior. Además, puesto que no se van a modificar, facilita su almacenamiento y distribución. El bucle se puede consultar en el cuaderno de Jupyter. No lo incluimos aquí por su extensión. En la Figura 4.5 se muestra un ejemplo de la estructura de una respuesta en formato JSON, cuyo contenido ha sido truncado para mayor claridad.

```

1  [
2    {
3      "value": 9.0,
4      "flagInfo": {
5        "hasFlags": false
6      },
7      "parameter": {
8        "id": 2,
9        "name": "pm25",
10       "units": "\u00b5g/m\u00b3",
11       "displayName": null
12     },
13     "period": {
14       "label": "raw",
15       "interval": "01:00:00",
16       "datetimeFrom": {
17         "utc": "2016-03-06T19:00:00Z",
18         "local": "2016-03-06T11:00:00-08:00"
19       },
20       "datetimeTo": {
21         "utc": "2016-03-06T20:00:00Z",
22         "local": "2016-03-06T12:00:00-08:00"
23       }
24     },
25     ...
26   }
27 ]

```

Figura 4.5: Ejemplo de respuesta JSON de la API de OpenAQ

4.1.3. Procesamiento de los datos descargados

Con la idea de integrar los datos de calidad del aire con los datos de asma, se ha creado una base de datos SQLite para facilitar el análisis posterior.

Se ha diseñado un esquema de base de datos que incluye tablas para las estaciones de medición, los sensores, las mediciones realizadas ... entre otros.

El esquema de las tablas se puede consultar en la Sección A.2.

En la Figura 4.6 se muestra un esquema generado por DBeaver de la base de datos.




Figura 4.6: Esquema de la BD en la Fase I

Más adelante, la base de datos se ampliará para incluir los datos de asma, permitiendo realizar consultas complejas que relacionen ambos conjuntos de datos.

Descripción del esquema de la base de datos

El esquema modela un sistema de **monitoreo ambiental** basado en estaciones y sensores, donde se registran mediciones de contaminantes a lo largo del tiempo. La estructura se compone de seis tablas principales y varias relaciones mediante claves foráneas.

- **units**: almacena las **unidades de medida** usadas en las mediciones (por ejemplo, $\mu g/m^3$, *ppm*). Contiene un identificador (`unit_id`), el nombre de la unidad (`unit_name`) y una descripción opcional (`description`).
- **pollutants**: catálogo de **contaminantes** medidos (por ejemplo, *NO₂*, *PM2.5*, *O₃*). Incluye `pollutant_id` y `pollutant_name`.
- **counties**: representa las **entidades geográficas** (condados). Guarda `county_id`, el nombre (`county_name`) y un campo `geometry` para almacenar la geometría (típicamente en formato texto, p. ej. WKT/GeoJSON).
- **stations**: define las **estaciones de monitoreo** asociadas a un condado. Cada estación (`station_id`) puede tener un `county_id` (clave foránea a `counties`) y coordenadas geográficas (`latitude`, `longitude`).

- **sensors**: modela los **sensores instalados en estaciones**. Un sensor (`sensor_id`) pertenece a una estación (`station_id`) y está asociado a un contaminante (`pollutant_id`) y a una unidad de medida (`unit_id`). Estas relaciones se implementan con claves foráneas hacia `stations`, `pollutants` y `units`.
- **measurements**: almacena las **mediciones** generadas por cada sensor.
Incluye `measurement_id`, el sensor (`sensor_id`), el valor medido (`measurement_value`) y el intervalo temporal de validez (`start_time`, `end_time`). Además, se define una restricción `UNIQUE(sensor_id, start_time, end_time)` para evitar duplicados del mismo sensor en el mismo intervalo.

Relaciones principales

- Un **condado** (`counties`) puede tener muchas **estaciones** (`stations`). Esto se define con `stations.county_id → counties.county_id`.
- Una **estación** puede tener muchos **sensores**. Esto se define con `sensors.station_id → stations.station_id`.
- Un **sensor** mide un **contaminante** y usa una **unidad**.
Esto se define con `sensors.pollutant_id → pollutants.pollutant_id` y `sensors.unit_id → units.unit_id`.
- Un **sensor** genera muchas **mediciones**. Esto se define con `measurements.sensor_id → sensors.sensor_id`.

4.2. Datos de prevalencia de asma en California

Los datos de prevalencia de asma en California se han obtenido de `data.gov`, la plataforma de datos abiertos del gobierno de Estados Unidos [1].

La iniciativa CHIS (California Health Interview Survey) proporciona datos detallados sobre la salud de la población californiana, incluyendo información sobre la prevalencia de asma. Estos datos describen la proporción de personas diagnosticadas con asma en distintos condados de California, desglosados por año, grupo de edad, género y otros factores demográficos. La extensión temporal de los datos abarca desde 2015 hasta 2021 (hasta el final de año), lo que permite analizar tendencias a lo largo del tiempo, si bien de forma limitada.

Debido a la urgencia de disponer de estos datos para el análisis, se ha optado por realizar este análisis con una cantidad limitada de años.

En futuras iteraciones del proyecto, se podría ampliar el rango temporal para obtener una visión más completa de la evolución de la prevalencia de asma en California.

Es por esto que se ha optado emplear una base de datos SQLite para integrar estos datos con los de calidad del aire. Permitiendo un mayor grado de extensibilidad y flexibilidad en el análisis posterior.

Similarmente a la fase anterior, se puede consultar el esquema actualizado de la base de datos en la Sección A.3.

El diagrama generado por DBeaver se muestra en la Figura 4.7.




Figura 4.7: Esquema tras implementar la segunda fuente

Descripción del esquema actualizado de la base de datos

Este esquema modela un conjunto de datos de **prevalencia de asma** por condado y por **grupo demográfico**, incluyendo intervalos de confianza.

Cabe mencionar que algunos condados pueden agruparse en ciertas observaciones, lo que se gestiona mediante una tabla intermedia.

La tabla principal es **asthma_prevalence**.

Cada fila representa una observación de prevalencia asociada a un **condado** (**county_id**) y a un **periodo temporal** definido por **year_from** y **year_to**.

La prevalencia se almacena en **current_prevalence**, y la incertidumbre se captura con el intervalo de confianza del 95 % mediante **ci_95_lower** y **ci_95_upper**.

El campo **comment** permite registrar notas o aclaraciones del dato (agrupaciones, incertidumbres...).

Además, la observación se vincula a una definición de subpoblación mediante **demographic_group_id**, y se mantiene integridad referencial con claves foráneas hacia **counties(county_id)** y **demographic_group(id)**.

La tabla `demographic_group` define los **grupos demográficos/poblacionales** empleados en el dataset.

El campo `strata` identifica la **subpoblación** al que corresponde el registro (por ejemplo, *All ages*, *Age groups* o *Child vs. Adult*).

El campo `age_group` conserva la etiqueta de edad exactamente como aparece en los datos originales.

Para facilitar análisis cuantitativos, `age_min` y `age_max` almacenan, cuando es posible, una normalización numérica del rango de edad. De esta forma es posible filtrar por intervalos (p. ej. 0–4, 5–17, 18–64, etc.) incluso si la etiqueta original es textual.

La tabla `grouped_counties` representa los casos en los que una observación del dataset corresponde a un **grupo de condados** (columna `COUNTIES GROUPED`).

Cada fila enlaza un `county_id` con un `asthma_prevalence_id`, permitiendo reconstruir exactamente qué condados están incluidos en esa agregación.

La clave primaria compuesta (`county_id`, `asthma_prevalence_id`) evita duplicidades y mantiene la consistencia de la relación.

En conjunto, el esquema separa la **medición** (prevalencia e intervalos) de las dimensiones **geográfica** (condados) y **poblacional** (estratos y edades). Esto permite consultas flexibles tanto para registros por condado individual como para resultados agregados por grupos de condados.

Capítulo 5

Análisis exploratorio: calidad del aire y prevalencia de asma

5.1. Objetivo y alcance del análisis

El objetivo de este capítulo es evaluar, de forma exploratoria, si existe evidencia empírica de una asociación entre los niveles de contaminación atmosférica y la prevalencia de asma en California a escala de condado. De acuerdo con la intuición epidemiológica y la literatura previa, cabría esperar que una mayor exposición a contaminantes se relacione con una mayor prevalencia de asma; sin embargo, los resultados obtenidos en este primer análisis no reflejan un patrón claro y consistente.

El análisis presentado debe interpretarse como una *primera aproximación* (screening) que sirve para: (i) validar que la integración de fuentes se ha realizado correctamente, (ii) detectar tendencias o anomalías gruesas, y (iii) orientar iteraciones posteriores más robustas (multianuales, multivariantes y con control de confusores).

5.2. Metodología

5.2.1. Variables y agregación

Para cada contaminante se resume la exposición mediante una métrica anual a nivel de condado. La variable de salud es la prevalencia de asma expresada como proporción/porcentaje de población diagnosticada, también a nivel de condado, empleando el estrato *Total population – All ages*.

La integración se realiza por condado (unidad geográfica común), lo que implica que el resultado es un análisis ecológico: se comparan promedios poblacionales y no exposiciones

individuales.

5.2.2. Medida de asociación y visualización

Como medida de asociación lineal se utiliza el coeficiente de correlación de Pearson, r , calculado entre:

- x : nivel anual del contaminante en el condado;
- y : prevalencia de asma en el condado.

Para facilitar la interpretación se representan los condados ordenados de mayor a menor contaminación (barras) y, sobre el mismo eje de condados, se superpone la prevalencia de asma (línea). Esta visualización permite comprobar si, al incrementar x (de izquierda a derecha), se observa un incremento sistemático de y .

5.3. Resultados

5.3.1. Material particulado fino ($PM_{2,5}$)

La Figura 5.1 muestra la comparación entre $PM_{2,5}$ y prevalencia de asma en el año base. A simple vista, no se observa un gradiente monotónico: condados con niveles relativamente altos de $PM_{2,5}$ no presentan necesariamente mayores prevalencias, y algunos máximos de prevalencia aparecen en posiciones intermedias o incluso con contaminación moderada.




Figura 5.1: $PM_{2,5}$ por condado (año base) y prevalencia de asma (*All ages*). Los condados se ordenan de mayor a menor nivel del contaminante. La ausencia de un patrón creciente claro sugiere que, en este corte temporal, la asociación lineal condal es débil o está enmascarada por otros factores.

5.3.2. Material particulado grueso (PM_{10})

La Figura 5.2 repite el análisis para PM_{10} . De nuevo, la prevalencia de asma no aumenta de forma sistemática con la contaminación. Además, se aprecia que ciertos condados pueden actuar como puntos de alta influencia (p.ej., valores extremos de contaminación) que condicionan cualquier medida lineal global.




Figura 5.2: PM₁₀ por condado (año base) y prevalencia de asma (*All ages*). Al igual que con PM_{2.5}, no se observa un gradiente claro de prevalencia al aumentar el contaminante. La presencia de valores extremos sugiere sensibilidad a outliers y refuerza la necesidad de análisis robustos y multivariantes.

5.4. Discusión: por qué los resultados no se corresponden con lo esperado

Que no aparezca una correlación clara en estas figuras no implica que la contaminación no tenga efecto sobre la salud respiratoria; más bien sugiere que, con el diseño actual, el efecto puede quedar *diluido* o *confundido*. Entre las explicaciones plausibles destacan:

5.4.1. Limitaciones temporales y desajustes de periodicidad

- **Corte en un solo año.** La relación contaminación–asma puede requerir acumulación de exposición, rezagos (lags) o cambios sostenidos durante varios años. Un único año reduce drásticamente la potencia para detectar señales consistentes.
- **Prevalencia de asma como estimación bianual.** Si la prevalencia se reporta por periodos (p.ej., $[year_from, year_to]$), el valor asignado a un año concreto representa una estimación agregada, lo que introduce suavizado temporal y puede ocultar variaciones interanuales.

5.4.2. Incertidumbre de la variable de salud

La prevalencia de asma suele estimarse mediante encuestas y/o procedimientos censales indirectos, por lo que incluye error muestral. Si el análisis utiliza únicamente el punto central, se ignora la variabilidad asociada. En escenarios con diferencias pequeñas entre condados, esa incertidumbre puede dominar la señal.

5.4.3. Heterogeneidad espacial y falacia ecológica

- **Agregación a nivel condado.** Dentro de un condado pueden coexistir zonas urbanas y rurales con exposiciones muy distintas. El promedio condal puede ser un mal proxy de la exposición real de la población.
- **Falacia ecológica.** La ausencia de correlación entre promedios agregados no invalida una relación causal a nivel individual, especialmente si existen subpoblaciones vulnerables (infancia, comorbilidades).

5.4.4. Confusión por factores externos a la calidad del aire

La prevalencia de asma puede depender de múltiples determinantes que no se han incluido en este análisis: nivel socioeconómico, acceso y uso del sistema sanitario, hábitos (p. ej., tabaquismo), condiciones de vivienda (humedad, moho), ocupación, alérgenos, clima/temperatura, incendios estacionales, etc. Si estos factores varían espacialmente y correlacionan con los contaminantes, pueden enmascarar (o incluso invertir) la asociación bivalente.

5.4.5. Cobertura y calidad de las mediciones de contaminantes

La cobertura espacial/temporal de estaciones no es homogénea entre contaminantes ni entre regiones. Condados con menos sensores pueden presentar estimaciones de exposición más ruidosas o sesgadas, lo que reduce la capacidad de detectar relaciones. Por tanto, estos resultados deben leerse junto con la evaluación de cobertura de sensores.

5.4.6. Relaciones no lineales y efectos de umbral

Es posible que la relación entre exposición y prevalencia no sea lineal (p. ej., umbrales regulatorios, saturación, o interacción con temperatura/humedad). En esos casos, r de Pearson y una inspección visual ordenada pueden no ser suficientes para revelar la dinámica real.

5.5. Líneas de trabajo futuro

A partir de estos hallazgos preliminares, las siguientes extensiones son prioritarias:

- **Análisis multianual (serie temporal).** Ampliar el periodo de estudio y modelar tendencias y rezagos (p.ej., medias móviles, correlaciones con desfase, modelos con efectos temporales).
- **Modelos multivariantes.** Incorporar covariables socio-demográficas y contextuales para controlar confusores y estimar efectos parciales.
- **Estratificación por edad.** Repetir el análisis en grupos etarios (infancia/adultos) para detectar señales específicas de subpoblaciones vulnerables, cuidando el tamaño muestral efectivo.
- **Componentes espaciales.** Evaluar autocorrelación espacial y considerar modelos con estructura espacial (p.ej., efectos aleatorios por región, suavizado espacial).
- **Robustez.** Usar medidas resistentes a outliers (Spearman, regresión robusta) y análisis de sensibilidad excluyendo condados extremos o con baja cobertura de sensores.

En conjunto, este capítulo confirma que, con el corte temporal y el nivel de agregación actuales, no se obtiene evidencia clara de una correlación lineal fuerte entre contaminación y prevalencia de asma. Lejos de invalidar la hipótesis, esto justifica la necesidad de un enfoque más rico (temporal, multivariante y espacial) para aproximar la complejidad del fenómeno.

Capítulo 6

Conclusiones y líneas de trabajo futuro

6.1. Síntesis del proyecto

El objetivo principal del proyecto ha sido estudiar, a escala de condado en California, la relación entre la calidad del aire (a través de contaminantes atmosféricos relevantes) y la prevalencia de asma, con una orientación clara hacia la reproducibilidad, la trazabilidad y la preservación a largo plazo de los activos digitales generados.

Para alcanzar este objetivo se ha abordado el ciclo completo de los datos: planificación y definición de requisitos, adquisición automatizada, curación e integración en una base de datos, análisis exploratorio e identificación de limitaciones, evaluación complementaria (cobertura/representatividad), y finalmente publicación y preservación.

6.2. Cumplimiento de objetivos y entregables

A nivel de ejecución, el proyecto deja como resultado un conjunto de activos reutilizables que permiten repetir y ampliar el estudio sin rehacer trabajo previo:

- Un flujo de trabajo reproducible para la obtención y tratamiento de datos, evitando correcciones manuales y facilitando auditoría de cambios.
- Un esquema de integración (base de datos) que separa medición, dimensión geográfica y dimensión poblacional, habilitando consultas flexibles por condado, periodo y estrato demográfico.
- Un conjunto de visualizaciones y resultados exploratorios orientados a detectar patrones y guiar iteraciones posteriores (en particular, multianuales y multivariantes).

- Un plan de preservación alineado con principios FAIR, con estrategias explícitas de almacenamiento, control de versiones y migración a formatos abiertos.

En conjunto, estos entregables satisfacen el requisito de construir una base técnica sólida para análisis posteriores y para la comunicación transparente de los resultados.

6.3. Conclusiones del análisis exploratorio

Los resultados obtenidos en el análisis bivalente (contaminantes vs. prevalencia) no muestran una asociación lineal clara y consistente en el año base considerado. Esta observación no es la esperada si se parte de la hipótesis intuitiva de que a mayor exposición media a contaminantes debería corresponder mayor prevalencia de asma. Sin embargo, la ausencia de un patrón fuerte en este corte no invalida la relación entre contaminación y salud respiratoria; más bien indica que, con el diseño actual, el efecto puede estar siendo amortiguado por limitaciones del dato o por factores no controlados.

Por tanto, la principal conclusión sustantiva de este informe es que el análisis ecológico y puntual (un solo año, agregación por condado) resulta insuficiente para capturar con robustez una relación que, por su naturaleza, puede ser acumulativa, no lineal, dependiente del contexto y afectada por múltiples confusores.

6.4. Limitaciones principales

Las limitaciones que probablemente explican la discrepancia entre lo esperado y lo observado pueden agruparse en cuatro bloques:

6.4.1. Limitaciones temporales

Trabajar con un único año reduce la potencia para identificar señales y no permite modelar dinámicas con rezago (*lag*) ni efectos de exposición acumulada. Además, cuando la variable de asma se reporta con periodicidad bianual o por periodos, el emparejamiento con un año concreto introduce suavizado temporal y puede ocultar variaciones relevantes.

6.4.2. Incertidumbre y naturaleza del dato epidemiológico

La prevalencia de asma suele ser una estimación (encuestas, inferencia poblacional) y puede incorporar incertidumbre no despreciable. Si el análisis utiliza únicamente valores puntuales

sin incorporar intervalos de confianza, se subestima la variabilidad y se reduce la interpretabilidad de diferencias pequeñas entre condados.

6.4.3. Agregación espacial y heterogeneidad intrarregional

La agregación por condado puede ocultar contrastes importantes (zonas urbanas vs. rurales) y conlleva riesgo de falacia ecológica: relaciones a nivel individual pueden no reflejarse en promedios agregados. Esto es especialmente relevante si existen subpoblaciones más vulnerables (infancia) cuyo patrón podría quedar diluido en *all ages*.

6.4.4. Factores externos y confusión

La prevalencia de asma depende de determinantes adicionales a la calidad del aire: nivel socioeconómico, acceso y uso del sistema sanitario, hábitos, condiciones de vivienda, alérgenos, clima, movilidad, y otros factores contextuales. Si estos factores varían espacialmente y se correlacionan con los contaminantes, el análisis bivariante puede no recuperar el efecto neto de la contaminación (o incluso producir asociaciones espurias).

6.5. Recomendaciones y trabajo futuro

A partir de lo anterior, se proponen líneas de trabajo que maximizan el valor científico del sistema construido:

6.5.1. Extensión multianual y análisis de series temporales

Dado que los datos abarcan varios años, la recomendación principal es ampliar el rango temporal y analizar tendencias. Algunas direcciones concretas:

- Modelos con desfases (*lags*) y medias móviles para capturar exposición acumulada.
- Comparación interanual por condado y detección de cambios estructurales (por ejemplo, periodos con incendios).
- Estimación de asociación dentro de cada condado a lo largo del tiempo, reduciendo parte de la confusión espacial.

6.5.2. Modelos multivariantes y control de confusores

Para acercarse a conclusiones causales (o al menos más interpretables) es necesario incorporar covariables socio-demográficas y contextuales. En particular:

- Ajuste por variables de estructura poblacional y determinantes sociales.
- Evaluación de interacciones (p. ej., contaminación $\times$ vulnerabilidad socioeconómica).
- Alternativas robustas ante outliers y distribuciones no gaussianas (correlación de Spearman, regresión robusta).

6.5.3. Estructura espacial y representatividad

Se recomienda integrar explícitamente componentes espaciales:

- Diagnóstico de autocorrelación espacial y patrones regionales.
- Modelos con efectos regionales o suavizado espacial, cuando proceda.
- Uso conjunto con la evaluación de cobertura de sensores para ponderar incertidumbre o excluir áreas con baja representatividad.

6.5.4. Estratificación y análisis por subpoblación

Aunque el análisis global es útil por estabilidad, una extensión natural es analizar estratos:

- Grupos de edad (infancia vs. adultos) para evaluar si la señal aparece en subpoblaciones más sensibles.
- Comparación de resultados entre estratos para detectar heterogeneidad de efectos.

6.6. Reproducibilidad, publicación y preservación

Más allá de los resultados numéricos, una contribución central del proyecto es haber construido un entorno reproducible y preservable: datos brutos diferenciados de datos curados, automatización de procesos, y una estrategia de preservación alineada con estándares abiertos y buenas prácticas (copias de seguridad, documentación, metadatos). Esto garantiza que el trabajo puede ser verificado, reutilizado y extendido, y reduce el coste marginal de incorporar nuevos años, nuevas variables o nuevas hipótesis.

6.7. Cierre

En conclusión, el proyecto ha cumplido con el objetivo de sentar una base técnica y metodológica sólida para estudiar la relación entre contaminación y asma en California, integrando fuentes heterogéneas y priorizando trazabilidad y reproducibilidad. El análisis exploratorio inicial sugiere que, con las restricciones actuales (corte temporal y agregación), no emerge una relación lineal fuerte; esta evidencia debe interpretarse como un punto de partida que justifica y orienta una segunda fase de análisis multianual, multivariante y espacial, más adecuada para reflejar la complejidad real del fenómeno.

Apéndice A

Código para la fase ETL

En este apéndice se presenta el código utilizado para la fase de Extracción, Transformación y Carga (ETL) de los datos en nuestro proyecto.

Las variables no definidas en los fragmentos de código se pueden consultar en la siguiente lista:

- `API_KEY`: Clave de API para acceder a la API de `OpenAQ`.
- `selected_stations`: `DataFrame` de `pandas` que contiene las estaciones seleccionadas para la descarga de datos históricos.

A.1. Extracción de datos de OpenAQ

```
1  # define bounding box for California
2  x_range = (-125, -113)
3  y_range = (32, 42.5)
4  import requests
5  BASE = "https://api.openaq.org/v3"
6  headers = {"X-API-Key": API_KEY}
7  all_results = []
8  page = 1
9  limit = 1000    # OpenAQ v3 maximum
10 while True:
11     r = requests.get(
12         f"{BASE}/locations",
13         headers=headers,
14         params={
15             "bbox": f"{x_range[0]},{y_range[0]},{x_range[1]},{y_range[1]}",
16             "limit": limit,
17             "page": page,
18             "country": "US",    # optional but helps validation
19         },
20         timeout=60,
21     )
22     r.raise_for_status()
23     data = r.json()
24
25     results = data.get("results", [])
26     if not results:
27         break
28
29     all_results.extend(results)
30     print(f"page {page}: {len(results)}")
31
32     page += 1
33
34 print("TOTAL returned:", len(all_results))
35 print("first name:", all_results[0].get("name"))
```

A.2. Esquema de primera fuente de datos

```
1 CREATE TABLE IF NOT EXISTS units(  
2     unit_id INTEGER PRIMARY KEY,  
3     unit_name VARCHAR(100) NOT NULL,  
4     description TEXT  
5 );  
6  
7 CREATE TABLE IF NOT EXISTS pollutants(  
8     pollutant_id INTEGER PRIMARY KEY,  
9     pollutant_name VARCHAR(100) NOT NULL  
10 );  
11  
12 CREATE TABLE IF NOT EXISTS stations(  
13     station_id INTEGER PRIMARY KEY,  
14     county_id INTEGER,  
15     latitude DECIMAL(9,6),  
16     longitude DECIMAL(9,6),  
17     FOREIGN KEY (county_id) REFERENCES counties(county_id)  
18 );  
19  
20 CREATE TABLE IF NOT EXISTS counties(  
21     county_id INTEGER PRIMARY KEY,  
22     county_name VARCHAR(100) NOT NULL,  
23     geometry TEXT  
24 );  
25  
26 CREATE TABLE IF NOT EXISTS sensors(  
27     sensor_id INTEGER PRIMARY KEY,  
28     station_id INTEGER,  
29     pollutant_id INTEGER,  
30     unit_id INTEGER,  
31     FOREIGN KEY (station_id) REFERENCES stations(station_id),  
32     FOREIGN KEY (pollutant_id) REFERENCES pollutants(pollutant_id),  
33     FOREIGN KEY (unit_id) REFERENCES units(unit_id)  
34 );  
35  
36 CREATE TABLE IF NOT EXISTS measurements(  
37     measurement_id INTEGER PRIMARY KEY,
```

```
38     sensor_id INTEGER,  
39     measurement_value DECIMAL(10,4) NOT NULL,  
40     start_time DATETIME NOT NULL,  
41     end_time DATETIME NOT NULL,  
42     FOREIGN KEY (sensor_id) REFERENCES sensors(sensor_id),  
43     UNIQUE(sensor_id, start_time, end_time)  
44 );
```

A.3. Esquema de segunda fuente de datos

```
1 CREATE TABLE IF NOT EXISTS asthma_prevalence (  
2     id INTEGER PRIMARY KEY,  
3     county_id INTEGER,  
4     year_from INTEGER,  
5     year_to INTEGER,  
6     demographic_group_id INTEGER,  
7     current_prevalence FLOAT,  
8     ci_95_lower FLOAT,  
9     ci_95_upper FLOAT,  
10    comment TEXT,  
11    FOREIGN KEY (county_id) REFERENCES counties(county_id),  
12    FOREIGN KEY (demographic_group_id) REFERENCES demographic_group(id)  
13 );  
14  
15 CREATE TABLE IF NOT EXISTS grouped_counties (  
16     -- Though it's a 1:N relationship, we create a separate table to allow for  
17     ↪ easier querying and future expansion  
18     county_id INTEGER,  
19     asthma_prevalence_id INTEGER,  
20     FOREIGN KEY (county_id) REFERENCES counties(county_id),  
21     FOREIGN KEY (asthma_prevalence_id) REFERENCES asthma_prevalence(id),  
22     PRIMARY KEY (county_id, asthma_prevalence_id)  
23 );  
24  
25 CREATE TABLE IF NOT EXISTS demographic_group (  
26     id INTEGER PRIMARY KEY,  
27     strata TEXT,  
28     age_group TEXT, -- as is from the data  
29     age_min INTEGER,  
30     age_max INTEGER  
31 );
```

Bibliografía

- [1] California Department of Public Health. Asthma prevalence. <https://catalog.data.gov/dataset/asthma-prevalence-6908c>, 2025. Data last modified: 2025-12-05. Metadata updated: 2025-12-23. Accessed: 2026-01-01.
- [2] jjaycez. Repository for the project. GitHub repository, 2026. URL: <https://github.com/jjaycez/data-life-cycle-project-2025>.
- [3] Haneen Khreis, Charlotte Kelly, James Tate, Roger Parslow, Karen Lucas, and Mark Nieuwenhuijsen. Exposure to traffic-related air pollution and risk of development of childhood asthma: A systematic review and meta-analysis. *Environment International*, 100:1–31, March 2017. URL: <https://www.sciencedirect.com/science/article/pii/S0160412016307838>, doi:10.1016/j.envint.2016.11.012.
- [4] Rajen N. Naidoo. NO₂ increases the risk for childhood asthma: a global concern. *The Lancet Planetary Health*, 3(4):e155–e156, April 2019. URL: [https://www.thelancet.com/journals/lanplh/article/PIIS2542-5196\(19\)30059-2/fulltext](https://www.thelancet.com/journals/lanplh/article/PIIS2542-5196(19)30059-2/fulltext), doi:10.1016/S2542-5196(19)30059-2.
- [5] Ruijing Ni, Hang Su, Richard T. Burnett, Yuming Guo, and Yafang Cheng. Long-term exposure to PM_{2.5} has significant adverse effects on childhood and adult asthma: A global meta-analysis and health impact assessment. *One Earth*, 7(11):1953–1969, 2024. URL: <https://www.sciencedirect.com/science/article/pii/S2590332224004871>, doi:10.1016/j.oneear.2024.09.022.
- [6] OpenAQ. OpenAQ documentation. <https://docs.openaq.org>. Accessed: 2026-01-01.
- [7] U.S. Census Bureau. TIGER/Line shapefiles: Counties (t1_2025_us_county.zip), 2025. Accessed: 2026-01-01. URL: https://www2.census.gov/geo/tiger/TIGER2025/COUNTY/t1_2025_us_county.zip.

- [8] U.S. Environmental Protection Agency. Health effects of ozone in patients with asthma and other chronic respiratory disease, June 2025. Last updated June 6, 2025. Accessed 2026-01-11. URL: <https://www.epa.gov/ozone-pollution-and-your-patients-health/health-effects-ozone-patients-asthma-and-other-chronic>.
- [9] World Health Organization. WHO global air quality guidelines: particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide, September 2021. Guideline. Published 22 September 2021. ISBN 978-92-4-003422-8. Accessed 2026-01-01. URL: <https://www.who.int/publications/i/item/9789240034228>.